

RECONOCIMIENTO DE PATRONES


AUTOMATIC CLASSIFICATION OF SLEEP STAGE FROM ECG SIGNAL USING A GATED- RECURRENT UNIT

GRUPO 3
LEONARDO SANDOVAL
RODOLFO HUACASI
DANIEL ZAVALETA

INTRODUCCION [1]


ELECTROCARDIOGRAMA

La señal ECG registra la actividad eléctrica del corazón, detectando ritmos y anomalías cardíacas a través de electrodos en la piel, crucial para diagnósticos cardíacos.



ESTADOS DEL SUEÑO

Los estados del sueño incluyen las etapas de sueño ligero, profundo y REM, cada una con características específicas de actividad cerebral y corporal, esenciales para la recuperación.



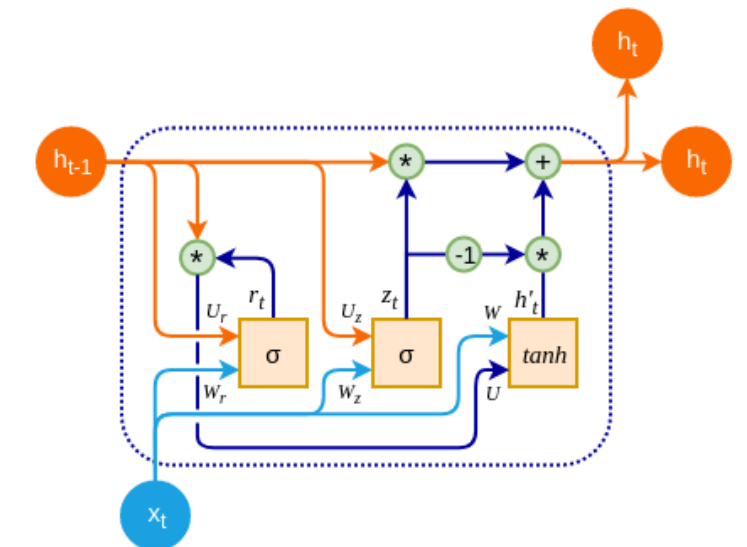
SEÑALES VITALES INTERMEDIAS

Las señales vitales intermedias monitorean funciones corporales críticas, como la presión arterial y la saturación de oxígeno, entre otras, brindando información sobre el estado fisiológico.




GATED RECURRENT UNIT

Los Gated Recurrent Units (GRU) son un tipo de red neuronal recurrente que utiliza puertas para controlar el flujo de información, mejorando el aprendizaje de secuencias largas.







ESTADO DEL ARTE



Sleep–wake stages classification and sleep efficiency estimation using singlelead electrocardiogram, [2]



 Expert Systems with Applications
Volume 39, Issue 1, January 2012, Pages 1401-1413

Sleep–wake stages classification and sleep efficiency estimation using single-lead electrocardiogram

Mourad Adnane^a , Zhongwei Jiang^a , Zhonghong Yan^b 


Show more 

+ Add to Mendeley  Share  Cite




<https://doi.org/10.1016/j.eswa.2011.08.022>  Get rights and content 


Abstract



Detecting sleep–wake stages is of paramount importance in the study of sleep.



 Computers in Biology and Medicine
Volume 78, 1 November 2016, Pages 138-143

A method of REM-NREM sleep distinction using ECG signal for unobtrusive personal monitoring

Jaspal Singh^a , R.K. Sharma^b , A.K. Gupta^b 

Show more 

+ Add to Mendeley  Share  Cite

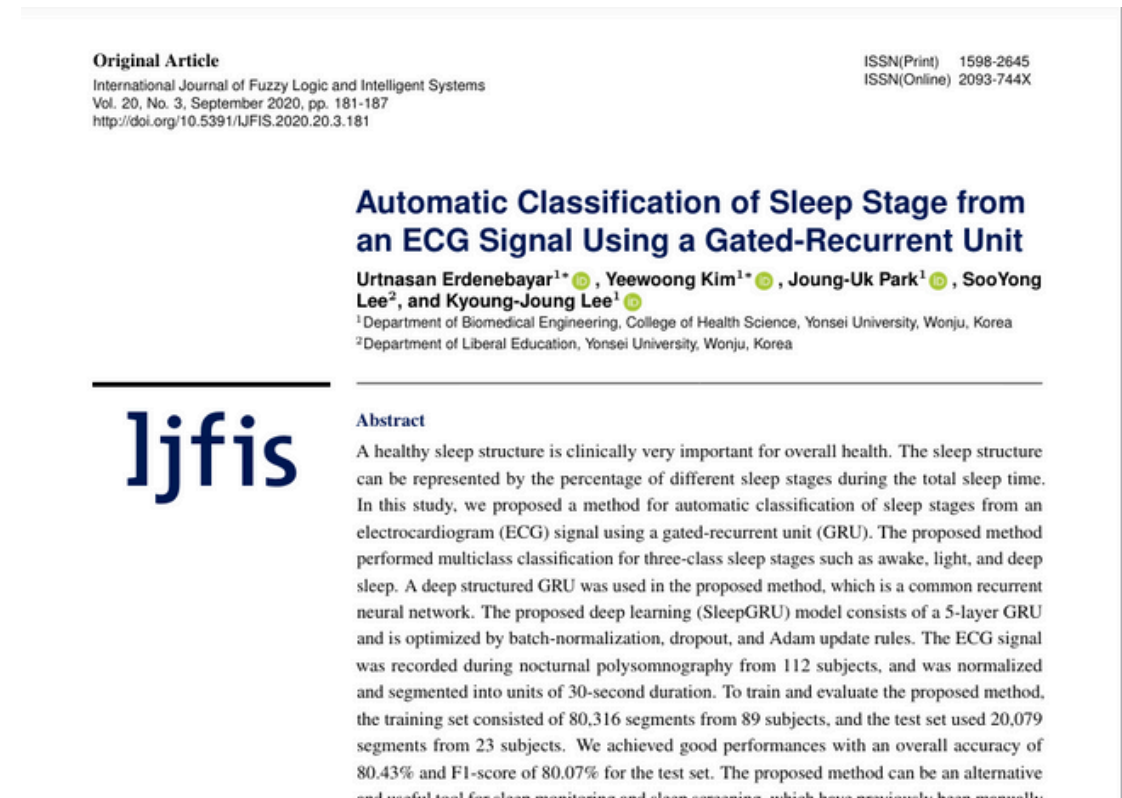

<https://doi.org/10.1016/j.combiomed.2016.09.018>  Get rights and content 

Highlights


- A method of identifying REM-NREM sleep based on ECG signal.

ESTADO DEL ARTE


Sleep stages classification based on heart rate variability and random forest[3]




OBJETIVO



Crear un metodo de clasificación automática para los estadios del sueño a partir de una señal ECG usando un Gated-recurrent unit.





DATASET

OBTENCIÓN DE SEÑALES ECG

- 112 participantes, 52 de control y 60 con Apnea
- Frecuencia de muestreo de 200 Hz.
- Segmentados en 30 segundos
- Estadios del sueño etiquetados según American Association of Sleep Medicine.
- Se utilizó un transductor de una derivación y se resampleó a 100 Hz con 3000 muestras por episodio para coleccionar la señal.
- El set de entrenamiento consiste de 80 316 episodios de 89 sujetos y el test de 20 070 episodios de 23 sujetos.

	Training set	Test set	Total
Sex	89	23	112
Male	55	16	71
Female	34	7	41
Age (yr)	53.1±10.5	55.1±10.4	53.5±10.5
BMI (kg/m ²)	24.2±3.0	24.2±3.0	24.2±3.0
AHI (/hr)	10.6±9.5	10.0±8.5	10.4±9.3
TST (hr)	6.2±1.0	6.2±0.7	6.2±0.9
SE (%)	84.8±13.1	86.0±8.7	85.1±12.3

Tabla 1. Informacion de los participantes

MODELO SLEEPGRU

El modelo SleepGRU consta de 5 capas GRU.
Mecanismo de compuerta de GRU:

$$z_t = g(W_z \cdot [h_{t-1}, x_t]), \quad (1)$$

$$r_t = g(W_r \cdot [h_{t-1}, x_t]), \quad (2)$$

$$\tilde{h}_t = \tanh(W \cdot [r_t \cdot h_{t-1}, x_t]), \quad (3)$$

$$h_t = (1 - z_t) \cdot h_{t-1} + z_t \cdot \tilde{h}_t, \quad (4)$$

Donde:

z_t : compuerta de actualización


r_t : la compuerta de reseteo

h 's: los vectores de activación de celda

σ : función de activación sigmoide

τ : función tangente hiperbólica

x_t : entrada a la celda actual




Estructura de la unidad de red neuronal:
Unidad recurrente cerrada (GRU) [5]


OPTIMIZACIÓN DEL MODELO SLEEPGRU

$$x_b = \alpha \cdot \left(\frac{x_i - \mu}{\sqrt{\sigma^2 + \varepsilon}} \right) + \beta,$$

**Batch
normalization**



Dropout



$$f(x) = \max(0, wx + b),$$

**Rectified linear
unit (ReLU)**

ESTRUCTURA DE MODELO SLEEPGRU

No	Layers	Units	Dropout	Feature maps	Params
1	bNorm	-	-	3000×1	4
2	GRU1	24	0.5	3000×24	1,920
3	GRU2	20	0.5	3000×20	2,760
4	GRU3	16	0.4	3000×16	1,824
5	GRU4	8	0.3	3000×8	642
6	GRU5	4	0.2	3000×4	168
7	MLP0	3	-	15×3	45

Tabla 2. Estructura detallada del
modo SleepGRU construido

IMPLEMENTACIÓN DEL MODELO SLEEPGRU


Preprocesamiento de
datos PSG



Construcción del
modelo



Estación de trabajo



EVALUACIÓN DEL MODELO

	Predicted Positive	Predicted Negative	
Actual Positive	TP <i>True Positive</i>	FN <i>False Negative</i>	Sensitivity $\frac{TP}{(TP + FN)}$
Actual Negative	FP <i>False Positive</i>	TN <i>True Negative</i>	Specificity $\frac{TN}{(TN + FP)}$
	Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

$$\begin{aligned} \text{F1 Score} &= \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}} \\ &= \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \end{aligned}$$

RESULTADOS

Table 3. The performance of the SleepGRU model

Datasets	Classes	Precision	Recall	F1	Accuracy (%)
Training set	Wake	0.86	0.68	0.76	84.01
	REM	0.88	0.67	0.77	
	NREM	0.86	0.90	0.89	
Test set	Wake	0.58	0.42	0.51	80.43
	REM	0.77	0.81	0.73	
	NREM	0.86	0.84	0.83	

DISCUSIÓN

Table 4. Comparison with previous studies

Author	Signal	Classes	Accuracy (%)
SVM [9]	HRV	2	79.9
Randon Forest [10]	HRV	3	72.5
SVM [11]	RR interval	2	72.8
Random Forest [12]	ECG	3	78.0
DNN [19]	ECG	3	77.8
CNN [20]	ECG	3	73.0
RNN [21]	HR, Activity	3	66.6
GRU	ECG	3	80.4

CONCLUSIONES

- El modelo SleepGRU clasifica automáticamente las etapas del sueño (despierto, REM y NREM).
- Usa una señal de ECG de una sola derivación.
- Logra una precisión del 80.43%.
- No requiere extracción de características.
- Se recomienda validar el modelo con conjuntos de datos más grandes y diversos en futuras investigaciones.

REFERENCIAS

- [1] U. Erdenebayar, Y. Kim, J.-U. Park, S. Lee, y K.-J. Lee, “Automatic Classification of Sleep Stage from an ECG Signal Using a Gated-Recurrent Unit”, Int. J. Fuzzy Log. Intell. Syst., vol. 20, n.o 3, pp. 181-187, sep. 2020, doi: 10.5391/IJFIS.2020.20.3.181.
- [2] M. Adnane, Z. Jiang, and Z. Yan, “Sleep–wake stages classification and sleep efficiency estimation using singlelead electrocardiogram,” Expert Systems with Applications, vol. 39, no. 1, pp. 1401-1413, 2012.
<https://doi.org/10.1016/j.eswa.2011.08.022>
- [3] M. Xiao, H. Yan, J. Song, Y. Yang, and X. Yang, “Sleep stages classification based on heart rate variability and random forest,” Biomedical Signal Processing and Control, vol. 8, no. 6, pp. 624-633, 2013.
<https://doi.org/10.1016/j.bspc.2013.06.001>
- [4] J. Singh, R. K. Sharma, and A. K. Gupta, “A method of REM-NREM sleep distinction using ECG signal for unobtrusive personal monitoring,” Computers in Biology and Medicine, vol. 78, pp. 138-143, 2016. <https://doi.org/10.1016/j.combiomed.2016.09.018>
- [5] P. Li et al., “Bidirectional Gated Recurrent Unit Neural Network for Chinese Address Element Segmentation”, ISPRS Int. J. Geo-Inf., vol. 9, n.o 11, Art. n.o 11, nov. 2020, doi: 10.3390/ijgi9110635.



GRACIAS

