

Desarrollo de un modelo de IA para la detección de patologías del sueño a partir del CAP Sleep Database

Rodolfo Roger Huacasi Turpo
Facultad de Ciencias y Filosofía
Universidad Peruana Cayetano Heredia
Lima, Perú
rodolfo.huacasi@upch.pe

Leonardo Sebastian Sandoval Carranza
Facultad de Ciencias y Filosofía
Universidad Peruana Cayetano Heredia
Lima, Perú
leonardo.sandoval@upch.pe

Daniel Ivan Zavaleta Guzmán
Facultad de Ciencias y Filosofía
Universidad Peruana Cayetano Heredia
Lima, Perú
daniel.zavaleta@upch.pe

Abstract—This document is a model and instructions for L^AT_EX. This and the IEEEtran.cls file define the components of your paper [title, text, heads, etc.]. *CRITICAL: Do Not Use Symbols, Special Characters, Footnotes, or Math in Paper Title or Abstract.

Index Terms—component, formatting, style, styling, insert

I. INTRODUCCIÓN

El sueño desempeña un papel crucial en la salud física y mental, influyendo directamente en una variedad de funciones corporales y cognitivas [1]. La falta de sueño se ha vinculado con un aumento en el riesgo de varias condiciones médicas como la obesidad, diabetes, enfermedades cardiovasculares y trastornos del ánimo [2] [3]. La privación de sueño conduce a una reducción de la calidad de vida y aumenta la mortalidad [4].

El Patrón Alternante Cíclico (CAP) es una onda EEG relacionada con la actividad del sueño NREM (sueño sin movimientos oculares rápidos) que indica la inestabilidad del sueño. Este indicador está relacionado con aspectos de la memoria y el ratio de aprendizaje [5], además de poder identificarse tanto en el sueño de adultos como de niños y, por lo tanto, representa una herramienta útil para la investigación de los trastornos del sueño a lo largo de la vida [6]. Entre algunos trastornos que este importante factor diagnóstico permite detectar, están el insomnio y la apnea obstructiva del sueño [7]. Asimismo, el CAP detecta anomalías espontáneas como el complejo K, que recientemente ha sido asociado con el Alzheimer y epilepsia [8].

Tradicionalmente, la evaluación del Patrón Alternante Cíclico (CAP) requiere un análisis visual detallado y laborioso por parte de especialistas entrenados. Este método, aunque es el gold estándar, es tedioso, consume mucho tiempo, es propenso a errores humanos y no detecta la microestructura del sueño como el CAP (el cual solo aparece durante unos pocos segundos, mucho menos que una época de 30s de duración) [7]. Además, la sutileza y complejidad de las señales EEG hacen que sin las herramientas adecuadas, la interpretación no solo sea un desafío, sino también susceptible a imprecisiones

significativas [9]. Esto limita su aplicabilidad en diagnósticos rápidos y accesibles, lo cual resalta las limitaciones en los métodos actuales de análisis de los patrones de sueño, específicamente del Patrón Alternante Cíclico (CAP), para la detección eficiente y precisa de patologías del sueño. Por lo tanto, surge la importancia de desarrollar modelos de aprendizaje automático que permitan la detección de patologías del sueño.

II. MATERIALES Y MÉTODOS

A. Adquisición de datos

Los datos empleados en este proyecto se obtuvieron de la CAP Sleep Database, una base de datos de acceso público que contiene 108 grabaciones polisomnográficas [10]. Estas grabaciones incluyen diversas señales, como EEG (3 canales), EOG (2 canales), EMG mentoniana y tibial, señales de respiración (flujo aéreo, esfuerzo abdominal y torácico y SaO₂) y EKG. Cada grabación, con una duración de un poco más de 8 horas, cuenta con anotaciones de referencia de las fases del sueño y de CAP.

Respecto a los sujetos de estudio, la base de datos registra 16 individuos sanos, sin trastornos neurológicos y libres de medicamentos que afecten al sistema nervioso central. Además, se cuenta con 92 individuos diagnosticados con alguna patología del sueño, distribuidos de la siguiente manera: 2 sujetos con bruxismo, 9 con insomnio, 5 con narcolepsia, 40 con epilepsia nocturna del lóbulo frontal, 10 con movimientos periódicos de las piernas, 22 con trastorno del comportamiento REM y 4 con trastornos respiratorios del sueño.

B. Metodología CRISP-DM

El proyecto se lleva a cabo bajo la metodología CRISP-DM, siguiendo una serie de etapas clave. En primer lugar, se definen objetivos generales y específicos orientados en la detección de patologías del sueño mediante el análisis de la base de datos CAP Sleep. Posteriormente, se explora la información contenida en el CAP Sleep Database, centrándonos especialmente en los datos polisomnográficos.

Una vez completada la comprensión inicial de datos, sigue la fase de preparación de los datos, donde se llevan a cabo tareas de preprocesamiento, como la limpieza y normalización de datos, para obtener una información relevante y estructurada de manera coherente. Luego, en la fase de modelado, se desarrollan varios modelos de machine learning utilizando la información extraída anteriormente, los cuales son entrenados y optimizados meticulosamente para mejorar su capacidad de detectar patologías del sueño.

En la fase de evaluación, cada modelo se somete a un análisis para evaluar su rendimiento, con enfoque en la precisión de sus resultados. Finalmente, en la etapa de despliegue, se implementa el modelo seleccionado en la plataforma Jetson Nano para su uso en tiempo real.

A continuación se muestran las etapas del proyecto y sus procesos a realizar en cada una de ellas.

Etapas 1: Metodología CRISP-DM

- Identificación de objetivos
- Exploración de datos
- Descargar y preprocesar los registros polisomnográficos de la CAP Sleep Database.
- Extraer características espectrales del EEG para identificar patrones característicos de CAP.

Etapas 2: Entrenamiento y evaluación de modelos

- Entrenar varios modelos de aprendizaje utilizando las características extraídas.
- Evaluar el rendimiento del modelo utilizando métricas de precisión, sensibilidad y especificidad en la detección.

Etapas 3: Implementación

- Despliegue del modelo seleccionado en la plataforma Jetson Nano.

C. Algoritmo propuesto

El algoritmo de clasificación para los datos seleccionados se basó en una red neuronal convolucional de una dimensión, debido a su menor carga computacional y a la eliminación de la necesidad de extraer características manualmente. Se llevó a cabo una optimización de hiper parámetros para identificar la función de pérdida y el optimizador que proporcionan la mayor precisión. Los hiper parámetros elegidos para el primer modelo fueron: optimizador Adam, tasa de aprendizaje de 0.001 y función de pérdida de entropía cruzada binaria.

La arquitectura del modelo propuesto comienza con una entrada de tamaño 1024, seguida de una capa de convolución de 1D con 32 filtros y una activación ReLU. Luego, se aplica una segunda capa de convolución de 1D con 8 filtros, seguida de una capa de max pooling. La red continúa con otra capa de convolución de 1D con 16 filtros, seguida de una segunda capa de max pooling. Los datos se aplanan y se procesan a través de capas densas completamente conectadas, finalizando en una salida sigmoide para la clasificación en dos fases (A y B).

REFERENCES

- [1] M. Tahmasian, F. Samea, H. Khazaie, M. Zarei, S. K. Masouleh, F. Hoffstaedter, J. Camilleri, P. Kochunov, B. T. Yeo, S. B. Eickhoff, and S. L. Valk, "The interrelation of sleep and mental and physical health is anchored in grey-matter neuroanatomy and under genetic control," *Communications Biology*, vol. 3, 2020.
- [2] E. Tobaldini, G. Costantino, M. Solbiati, C. Cogliati, T. Kara, L. Nobili, and N. Montano, "Sleep, sleep deprivation, autonomic nervous system and cardiovascular diseases," *Neuroscience & Biobehavioral Reviews*, vol. 74, pp. 321–329, 2017, stress, Behavior and the Heart. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0149763416302184>
- [3] K. R. Sewell, K. I. Erickson, S. R. Rainey-Smith, J. J. Peiffer, H. R. Sohrabi, and B. M. Brown, "Relationships between physical activity, sleep and cognitive function: A narrative review," *Neuroscience & Biobehavioral Reviews*, vol. 130, pp. 369–378, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0149763421003857>
- [4] S. C. Liew and T. Aung, "Sleep deprivation and its association with diseases- a review," *Sleep Medicine*, vol. 77, pp. 192–204, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1389945720303701>
- [5] R. Ferri, R. Huber, D. Arico, V. Drago, F. Rundo, M. F. Ghilardi, M. Massimini, and G. Tononi, "The slow-wave components of the cyclic alternating pattern (cap) have a role in sleep-related learning processes," *Neuroscience Letters*, vol. 432, no. 3, pp. 228–231, 2008. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0304394007012992>
- [6] L. Parrino, R. Ferri, O. Bruni, and M. G. Terzano, "Cyclic alternating pattern (cap): The marker of sleep instability," *Sleep Medicine Reviews*, vol. 16, no. 1, pp. 27–45, 2012. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S108707921100027X>
- [7] H. W. Loh, C. P. Ooi, S. G. Dhok, M. Sharma, A. A. Bhurane, and U. R. Acharya, "Automated detection of cyclic alternating pattern and classification of sleep stages using deep neural network," *Applied Intelligence*, vol. 52, 2022.
- [8] M. H. Gandhi and P. D. Emmady, "Physiology, K Complex," in *StatPearls*. Treasure Island (FL): StatPearls Publishing, 2024. [Online]. Available: <http://www.ncbi.nlm.nih.gov/books/NBK557469/>
- [9] Z. Wan, R. Yang, M. Huang, N. Zeng, and X. Liu, "A review on transfer learning in eeg signal analysis," *Neurocomputing*, vol. 421, pp. 1–14, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231220314223>
- [10] M. G. Terzano, L. Parrino, A. Sherieri, R. Chervin, S. Chokroverty, C. Guilleminault, M. Hirshkowitz, M. Mahowald, H. Moldofsky, A. Rosa, R. Thomas, and A. Walters, "Atlas, rules, and recording techniques for the scoring of cyclic alternating pattern (cap) in human sleep," *Sleep Medicine*, vol. 2, no. 6, pp. 537–553, 2001. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1389945701001496>