

Clasificador Híbrido LSTM-1D CNN para fases del patrón ciclico alternante del sueño (CAP)

Rodolfo Roger Huacasi Turpo

Facultad de Ciencias e Ingeniería

Universidad Peruana Cayetano Heredia

Lima, Perú

rodolfo.huacasi@upch.pe

Leonardo Sebastian Sandoval Carranza

Facultad de Ciencias e Ingeniería

Universidad Peruana Cayetano Heredia

Lima, Perú

leonardo.sandoval@upch.pe

Daniel Ivan Zavaleta Guzmán

Facultad de Ciencias e Ingeniería

Universidad Peruana Cayetano Heredia

Lima, Perú

daniel.zavaleta@upch.pe

Abstract—El sueño es esencial para la salud física y mental, y su falta se asocia con diversas condiciones médicas. El Patrón Alternante Cíclico (CAP), una característica microestructural del sueño NREM visible en el EEG, refleja la calidad del sueño y está relacionado con varios trastornos del sueño. Sin embargo, su análisis visual es tedioso y propenso a errores. Este estudio presenta un modelo de red neuronal convolucional unidimensional (1-D CNN) combinado con una red de memoria a corto y largo plazo (LSTM) para la detección automática del CAP. Se utilizaron datos de la base de datos CAP Sleep Database, preprocesados y equilibrados para obtener señales de pacientes sanos y con diferentes patologías del sueño. Este enfoque automatizado ofrece un paso adelante en la implementación clínica de la evaluación del CAP, proporcionando una herramienta potencialmente eficiente y precisa para el diagnóstico de trastornos del sueño.

I. INTRODUCCIÓN

El sueño desempeña un papel crucial en la salud física y mental, influyendo directamente en una variedad de funciones corporales y cognitivas [1]. La falta de sueño se ha vinculado con un aumento en el riesgo de varias condiciones médicas como la obesidad, diabetes, enfermedades cardiovasculares y trastornos del ánimo [2] [3]. La privación de sueño conduce a una reducción de la calidad de vida y aumenta la mortalidad [4].

El Patrón Alternante Cíclico (CAP) es una característica microestructural del sueño identificable en el EEG, que se encuentra presente en el estado del sueño NREM (sueño sin movimientos oculares rápidos) y ayuda en la evaluación de la calidad del sueño, así como en la identificación de trastornos del sueño [5]. El CAP consiste en ciclos alternantes de alta y baja actividad cortical, definidos como fases A y B, respectivamente [6]. La fase A consiste en periodos de ondas lentas de alto voltaje junto con ritmos rápidos de baja amplitud. Esta fase se subdivide en tres subgrupos según la combinación de ritmos lentos y rápidos: A1, A2 y A3. Tras cada fase A, sigue la fase B, que se define por ser actividad de bajo voltaje e irregular [7]. Un ciclo CAP está compuesto por un par de fases A y B, donde cada fase dura entre 2 y 60 segundos, y un mínimo de dos ciclos CAP sucesivos forma una secuencia CAP [5] [8].

Este indicador está relacionado con aspectos de la memoria y el ratio de aprendizaje [9], además de poder identificarse

tanto en el sueño de adultos como de niños y, por lo tanto, representa una herramienta útil para la investigación de los trastornos del sueño a lo largo de la vida [10].

Aunque el CAP es un fenómeno fisiológico, también indica inestabilidad del sueño y está asociado a diversos trastornos patológicos relacionados con el sueño [8]. En particular, se ha observado que la frecuencia de eventos CAP es significativamente superior en personas con limitación del flujo inspiratorio comparado con sujetos sanos [11]. De igual manera, incrementos en los ciclos CAP están vinculados con trastornos del sueño como la apnea del sueño, insomnio, movimientos periódicos de las piernas, síndrome de piernas inquietas, parasomnias como el trastorno de conducta del sueño REM y epilepsia frontal nocturna [8] [12]. El CAP también es útil para detectar anomalías espontáneas como el complejo K, asociado con condiciones como Alzheimer y epilepsia [13].

El CAP refleja de manera precisa la inestabilidad del sueño, no obstante, su análisis no ha sido completamente adoptado en la práctica clínica debido a diversas limitaciones. El actual método gold estándar para la evaluación del CAP es mediante la identificación visual de las fases del CAP por especialistas entrenados, lo cual es tedioso y consume mucho tiempo, y además está sujeto a errores humanos que pueden llevar a una categorización inexacta [12] [14]. Además, la sutileza y complejidad de las señales EEG hacen que sin las herramientas adecuadas, la interpretación no solo sea un desafío, sino también sea susceptible a imprecisiones significativas [15]. Ante estos retos, surge la necesidad de desarrollar métodos automáticos de análisis de EEG que sean eficientes y precisos. En años recientes, el desarrollo de algoritmos y métodos de análisis automático del CAP, al igual de marcadores basados en el CAP, han empezado a facilitar el uso más generalizado del CAP en el diagnóstico de patologías del sueño [5] [8].

II. ANTECEDENTES

Entre los diversos modelos automáticos desarrollados para la detección CAP en los últimos años, muchos de estos han utilizado técnicas de aprendizaje automático (machine learning; ML) y aprendizaje profundo (deep learning; DL) debido a la facilidad de implementación y menor margen de error. En el caso de ML, la selección y extracción de características representan los mayores desafíos, ya que requieren

datos preprocesados de alto nivel. En contraste, DL integra la extracción de características dentro de las capas neuronales, lo que disminuye la necesidad de preprocesamiento de datos. Aunque el rendimiento de clasificación de ambas técnicas es similar, los modelos basados en DL han reportado un rendimiento ligeramente superior. Los clasificadores de ML más utilizados son SVM y KNN, mientras que 1D-CNN es frecuente en DL [5].

En el estudio de Loh et al. [12], se propone un modelo de aprendizaje profundo basado en redes neuronales convolucionales de una dimensión (1D-CNN) para la detección del CAP y la clasificación de tres etapas del sueño (vigilia, REM y NREM). El modelo, desarrollado a partir de registros EEG estandarizados, alcanzó una exactitud de clasificación del 90.46% para las etapas del sueño y del 73.64% en un dataset equilibrado de CAP, con una sensibilidad del 92.06% en un dataset desequilibrado. Este estudio destaca la dificultad de profesionales expertos para discernir cambios sutiles en las señales EEG durante el sueño NREM.

Por otro lado, Sharma et al. [16] se centraron en el uso en un banco de filtros wavelet biortogonales (BOWFB) para identificar las fases del CAP. El modelo de aprendizaje automático desarrollado utilizó varios algoritmos de ML supervisados y logró una exactitud media de clasificación del 74.40%, y una exactitud máxima del 87.83% con un dataset desequilibrado. El modelo fue validado con técnicas como validación cruzada y validación hold out.

Además, en otro estudio [17] presentaron un modelo denominado CAPSCNet, que es basa en una variante de CNN llamada red de dispersión wavelet (WSN), para detectar automáticamente las fases A del CAP en señales EEG. Las WSNs son más sencillas y computacionalmente más eficientes que las redes neuronales convolucionales (CNN). En este estudio, la WSN empleada extrae automáticamente características de los datos de EEG, y luego estas características son introducidas en diferentes clasificadores de ML supervisados. Este modelo CAPSCNet alcanzó una exactitud de clasificación promedio del 83.4% con un clasificador de red neuronal tricapa en datos de sujetos sanos. Este estudio utilizó variantes de datos de siete cohortes de sueño CAP para probar el modelo, destacando su eficacia y velocidad computacional.

Asimismo, Kahana et al. [18] exploraron un algoritmo automático basado en DL que utiliza arquitectura de CNN para clasificar señales EEG según sus representaciones tiempo-frecuencia. Este estudio emplea representaciones basadas en Wigner, las cuales superan a la transformada de Fourier de tiempo corto comúnmente utilizada para la clasificación del CAP. El algoritmo, que también incorpora técnicas de aumento de datos para preservar la estructura tiempo-frecuencia, logró una exactitud del 77.5% en un dataset de testeo equilibrado y del 81.8% en uno desequilibrado, lo cual muestra su potencial para mejorar procedimientos de identificación del CAP.

III. MATERIALES Y MÉTODOS

A. Participantes y Datasets

Los datos empleados en este proyecto se obtuvieron de la CAP Sleep Database, una base de datos de acceso público que contiene 108 grabaciones polisomnográficas [19]. Estas grabaciones incluyen diversas señales, como EEG (3 canales), EOG (2 canales), EMG mentoniana y tibial, señales de respiración (flujo aéreo, esfuerzo abdominal y torácico y SaO₂) y EKG. Cada grabación, con una duración de un poco más de 8 horas, cuenta con anotaciones de referencia de las fases del sueño y del CAP.

Respecto a los sujetos de estudio, la base de datos registra 16 individuos sanos, sin trastornos neurológicos y libres de medicamentos que afecten al sistema nervioso central. Además, se cuenta con 92 individuos diagnosticados con alguna patología del sueño, distribuidos de la siguiente manera: 2 sujetos con bruxismo, 9 con insomnio, 5 con narcolepsia, 40 con epilepsia nocturna del lóbulo frontal, 10 con movimientos periódicos de las piernas, 22 con trastorno del comportamiento REM y 4 con trastornos respiratorios del sueño. Los datos se adquirieron durante la noche, con una duración aproximada de 9 a 10 horas.

B. Preprocesamiento de datos

Los data balanceada y preprocesada de CAP Sleep Database fue obtenida de un repositorio de Kaggle, previamente utilizado para la creación de una red 1D-CNN de clasificación. [12]. Se utilizaron las señales EEG que presentaban una frecuencia de muestreo (f_s) de 512 Hz y se utilizó el canal F4-C4. Estos datos fueron posteriormente divididos en periodos de 2 segundos (T). Únicamente se seleccionaron los datos de sueño correspondientes a las fases A y B del CAP. Para cada señal se utilizaron 1024 muestras ($n = 1024$). La relación entre los parámetros de adquisición de la señal se muestra en la siguiente ecuación (1):

$$T = \frac{n}{f_s} = 2 \text{ s} \quad (1)$$

Los data obtenida incluye 9306 señales de 6 pacientes sanos balanceada equitativamente, para obtener el mismo numero de señales con fases A y B. Para el experimento, también se seleccionaron pacientes con distintas patologías. La distribución de las señales balanceadas para cada patología incluye:

- 6 Pacientes con insomnio, generando un total de 9960 señales.
- 5 Pacientes con narcolepsia, generando un total de 9558 señales.
- 40 Paciente con Epilepsia nocturna del lóbulo frontal (NFLE), generando un total de 73263 señales.
- 8 Pacientes con Trastorno de movimientos periódicos de las extremidades (PLM) generando un total de 17934
- 22 Pacientes con trastorno de conducta del sueño REM (RBD) generando un total de 44100 señales.

El mismo principio de balanceo aplicado a los pacientes sanos se utilizó para las señales patológicas.

C. 1-D CNN

En el modelo se emplea una red neuronal convolucional unidimensional (1-D CNN) para procesar los datos.

Las CNN generan nuevos atributos con mayor información a partir de una capa previa de convolución. Posteriormente, se reduce la dimensionalidad mediante una capa de Max Pooling. Además, cada una de estas capas presenta una función de activación. Finalmente, la salida de estas capas se conecta a una capa densamente conectada que prepara la salida final.

En la arquitectura propuesta, se utiliza una 1-D CNN con una función de activación ReLU y una forma de datos de entrada (input shape) de 1024x1. La capa de Max Pooling mantiene el valor máximo en una vecindad de tamaño 2.

D. LSTM

Posteriormente los datos pasan por una capa LSTM (Long short term memory). El LSTM (Long Short-Term Memory) es un tipo de red neuronal recurrente comúnmente utilizado en datos secuenciales o análisis de series temporales. Estas redes están basadas en celdas de memoria diseñadas para almacenar información durante largos períodos de tiempo y también para retener información a corto plazo.

La LSTM consiste en tres compuertas o gates: la compuerta de entrada (input gate), la compuerta de olvido (forget gate) y la compuerta de salida (output gate). Estas compuertas deciden el flujo de información basándose en el dato de entrada actual, los estados internos previos (memoria a largo plazo y a corto plazo). La compuerta de olvido principalmente determina cuánta información previa se conservará para las siguientes iteraciones.

Las entradas de las compuertas se determinan principalmente mediante sus funciones de activación, comúnmente funciones sigmoide y tangente hiperbólica para asegurar valores dentro del rango [0,1] y [-1,1] respectivamente. Las ecuaciones actualizadas se presentan a continuación (2).

$$\begin{aligned}
 h(t) &= g_0(t) \cdot f_h(s(t)) \cdot s(t-1) \\
 s(t) &= g_f(t) \cdot s(t-1) + g_i(t) \cdot f_s(w_h(t-1)) + u_X(t) + b \\
 g_i(t) &= \sigma(w_i h(t-1) + u_i X(t) + b_i) \\
 g_f(t) &= \sigma(w_f h(t-1) + u_f X(t) + b_f) \\
 g_o(t) &= \sigma(w_o h(t-1) + u_o X(t) + b_o)
 \end{aligned} \tag{2}$$

Donde h representa la salida en el tiempo t , s es el estado interno, g_0 , g_f , g_i y g_o son las funciones de las compuertas, f_h y f_s son funciones de activación para los estados, w y u son pesos ajustables de la matriz, y b son los sesgos. Es importante destacar que los valores de los pesos no varían para permitir la entrada de secuencias largas.

En el modelo, se utilizó 16 unidades de memoria. Previo a la salida esta paso por una capa densamente conectada de 16 neuronas con función de activación reLu. El resumen de la arquitectura se encuentra en la Tabla I.

El optimizador seleccionado fue Adam, con una función de pérdida de entropía cruzada y como principal métrica la

Tabla I
ARQUITECTURA DETALLADA DEL MODELO LSTM-CNN

Capa (tipo)	Forma de salida	Parámetros entrenables
Conv 1D	(None, 1022, 64)	128
Conv 1D	(None, 1020, 8)	776
MaxPooling 1D	(None, 63, 8)	0
Conv 1D	(None, 61, 16)	400
Dropout	(None, 61, 16)	0
Conv 1D	(None, 59, 8)	392
MaxPooling 1D	(None, 14, 8)	0
LSTM	(None, 16)	1,600
Dense	(None, 16)	272
Dense	(None, 2)	34

exactitud. El modelo se probó a 500 épocas para evaluar su rendimiento.

IV. RESULTADOS

Los resultados obtenidos de la arquitectura LSTM-CNN fueron los presentados en la Figura 1, donde se presentan las gráficas de pérdida y exactitud a lo largo de las 500 épocas. La exactitud de validación se mantiene alrededor del 64% a partir de la época 150 aproximadamente. Se intentó corregir el overfitting utilizando regularización L1 y L2, sin embargo esto no mejoró los resultados. La exactitud del testeo obtenido fue 64.80% y la matriz de confusión se muestra en la Figura 2.

REFERENCIAS

- [1] M. Tahmasian, F. Samea, H. Khazaie, M. Zarei, S. K. Masouleh, F. Hoffstaedter, J. Camilleri, P. Kochunov, B. T. Yeo, S. B. Eickhoff, and S. L. Valk, "The interrelation of sleep and mental and physical health is anchored in grey-matter neuroanatomy and under genetic control," *Communications Biology*, vol. 3, 2020.
- [2] E. Tobaldini, G. Costantino, M. Solbiati, C. Cogliati, T. Kara, L. Nobili, and N. Montano, "Sleep, sleep deprivation, autonomic nervous system and cardiovascular diseases," *Neuroscience & Biobehavioral Reviews*, vol. 74, pp. 321–329, 2017, stress, Behavior and the Heart. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0149763416302184>
- [3] K. R. Sewell, K. I. Erickson, S. R. Rainey-Smith, J. J. Peiffer, H. R. Sohrabi, and B. M. Brown, "Relationships between physical activity, sleep and cognitive function: A narrative review," *Neuroscience & Biobehavioral Reviews*, vol. 130, pp. 369–378, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0149763421003857>
- [4] S. C. Liew and T. Aung, "Sleep deprivation and its association with diseases- a review," *Sleep Medicine*, vol. 77, pp. 192–204, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1389945720303701>
- [5] M. Sharma, H. Lodhi, R. Yadav, H. Elphick, and U. R. Acharya, "Computerized detection of cyclic alternating patterns of sleep: A new paradigm, future scope and challenges," *Computer Methods and Programs in Biomedicine*, vol. 235, p. 107471, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0169260723001372>
- [6] U. Seneviratne, M. Cook, and W. D'Souza, "Epileptiform k-complexes and sleep spindles: An underreported phenomenon in genetic generalized epilepsy," *Journal of Clinical Neurophysiology*, vol. 33, no. 2, 2016.
- [7] Y. Gu, J.-F. Gagnon, and M. Kaminska, "Sleep electroencephalography biomarkers of cognition in obstructive sleep apnea," *Journal of Sleep Research*, vol. 32, no. 5, p. e13831, 2023.




Figura 1. Función de pérdida y exactitud del modelo




Figura 2. Matriz de confusión. Las etiquetas 1 y 0 corresponden a las fases A y B del CAP, respectivamente.

- [8] D. Gu, Y. Mi, and A. Lin, "Application of time-delay multiscale symbolic phase compensated transfer entropy in analyzing cyclic alternating pattern (cap) in sleep-related pathological data," *Communications in Nonlinear Science and Numerical Simulation*, vol. 99, p. 105835, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1007570421001477>
- [9] R. Ferri, R. Huber, D. Aricò, V. Drago, F. Rundo, M. F. Ghilardi, M. Massimini, and G. Tononi, "The slow-wave components of the cyclic alternating pattern (cap) have a role in sleep-related learning processes," *Neuroscience Letters*, vol. 432, no. 3, pp. 228–231, 2008. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0304394007012992>
- [10] L. Parrino, R. Ferri, O. Bruni, and M. G. Terzano, "Cyclic alternating pattern (cap): The marker of sleep instability," *Sleep Medicine Reviews*, vol. 16, no. 1, pp. 27–45, 2012.
- [11] A. Parekh, K. Kam, A. E. Mullins, B. Castillo, A. Berkaliyeva, M. Mazumdar, A. W. Varga, D. J. Eckert, D. M. Rapoport, and I. Ayappa, "Altered K-complex morphology during sustained inspiratory airflow limitation is associated with next-day lapses in vigilance in obstructive sleep apnea," *Sleep*, vol. 44, no. 7, p. zsab010, 01 2021.
- [12] H. W. Loh, C. P. Ooi, S. G. Dhok, M. Sharma, A. A. Bhurane, and U. R. Acharya, "Automated detection of cyclic alternating pattern and classification of sleep stages using deep neural network," *Applied Intelligence*, vol. 52, 2022.

- [13] M. H. Gandhi and P. D. Emmady, "Physiology, K Complex," in *StatPearls*. Treasure Island (FL): StatPearls Publishing, 2024. [Online]. Available: <http://www.ncbi.nlm.nih.gov/books/NBK557469/>
- [14] M. P. Tramonti Fantozzi, U. Faraguna, A. Ugon, G. Ciuti, and A. Pinna, "Automatic cyclic alternating pattern (cap) analysis: Local and multi-trace approaches," *Plos one*, vol. 16, no. 12, p. e0260984, 2021.
- [15] Z. Wan, R. Yang, M. Huang, N. Zeng, and X. Liu, "A review on transfer learning in eeg signal analysis," *Neurocomputing*, vol. 421, pp. 1–14, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231220314223>
- [16] M. Sharma, A. A. Bhurane, and U. R. Acharya, "An expert system for automated classification of phases in cyclic alternating patterns of sleep using optimal wavelet-based entropy features," *Expert Systems*, vol. 41, no. 5, p. e12939, 2024. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1111/exsy.12939>
- [17] M. Sharma, S. Verma, D. Anand, V. M. Gadre, and U. R. Acharya, "Capsnet: A novel scattering network for automated identification of phasic cyclic alternating patterns of human sleep using multivariate eeg signals," *Computers in Biology and Medicine*, vol. 164, p. 107259, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482523007242>
- [18] Y. Kahana, A. Aberdam, A. Amar, and I. Cohen, "Deep-learning-based classification of cyclic-alternating-pattern sleep phases," *Entropy*, vol. 25, no. 10, 2023. [Online]. Available: <https://www.mdpi.com/1099-4300/25/10/1395>
- [19] M. G. Terzano, L. Parrino, A. Sherieri, R. Chervin, S. Chokroverty, C. Guilleminault, M. Hirshkowitz, M. Mahowald, H. Moldofsky, A. Rosa, R. Thomas, and A. Walters, "Atlas, rules, and recording techniques for the scoring of cyclic alternating pattern (cap) in human sleep," *Sleep Medicine*, vol. 2, no. 6, pp. 537–553, 2001. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1389945701001496>