

Clasificadores Híbridos LSTM-1D CNN para la identificación de fases y patologías del patrón cíclico alternante del sueño (CAP)

Rodolfo Roger Huacasi Turpo
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
rodolfo.huacasi@upch.pe

Leonardo Sebastian Sandoval Carranza
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
leonardo.sandoval@upch.pe

Daniel Ivan Zavaleta Guzmán
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
daniel.zavaleta@upch.pe

Abstract—El sueño juega un papel fundamental en la salud física y mental, influyendo en numerosas funciones corporales y cognitivas. La falta de sueño se asocia con un mayor riesgo de enfermedades como la obesidad, diabetes, enfermedades cardiovasculares y trastornos del ánimo. El Patrón Alternante Cíclico (CAP) es una característica microestructural del sueño observable en el electroencefalograma (EEG) que evalúa la calidad del sueño y ayuda a identificar trastornos del sueño. Este estudio aborda el desarrollo de métodos automáticos de análisis de EEG para detectar y clasificar fases del CAP y patologías del sueño, superando las limitaciones de la evaluación visual tradicional. Se emplearon modelos de aprendizaje automático y profundo, incluyendo 1D-CNN, GRU y LSTM, utilizando datos de la CAP Sleep Database. Los resultados mostraron mejoras significativas en la precisión de clasificación de fases CAP y demostraron su efectividad al clasificar patologías del sueño, destacando la eficiencia y potencial de estos métodos para el diagnóstico y tratamiento de este tipo de trastornos.

I. INTRODUCCIÓN

El sueño desempeña un papel crucial en la salud física y mental, influyendo directamente en una variedad de funciones corporales y cognitivas [1]. La falta de sueño se ha vinculado con un aumento en el riesgo de varias condiciones médicas como la obesidad, diabetes, enfermedades cardiovasculares y trastornos del ánimo [2] [3]. La privación de sueño conduce a una reducción de la calidad de vida y aumenta la mortalidad [4].

El Patrón Alternante Cíclico (CAP, por sus siglas en inglés) es una característica microestructural del sueño identificable en el electroencefalograma (EEG), que se encuentra presente en el estado del sueño NREM (sueño sin movimientos oculares rápidos) y ayuda en la evaluación de la calidad del sueño, así como en la identificación de trastornos del sueño [5]. El CAP consiste en ciclos alternantes de alta y baja actividad cortical, definidos como fases A y B, respectivamente [6]. La fase A consiste en periodos de ondas lentas de alto voltaje junto con ritmos rápidos de baja amplitud. Esta fase se subdivide en tres subgrupos según la combinación de ritmos lentos y rápidos: A1, A2 y A3. Tras cada fase A, sigue la fase B, que se define por ser actividad de bajo voltaje e irregular [7]. Un ciclo CAP está compuesto por un par de fases A y B, donde cada fase

dura entre 2 y 60 segundos, y un mínimo de dos ciclos CAP sucesivos forma una secuencia CAP [5] [8].

Este indicador está relacionado con aspectos de la memoria y el ratio de aprendizaje [9], además de poder identificarse tanto en el sueño de adultos como de niños y, por lo tanto, representa una herramienta útil para la investigación de los trastornos del sueño a lo largo de la vida [10].

Aunque el CAP es un fenómeno fisiológico, también indica inestabilidad del sueño y está asociado a diversos trastornos patológicos relacionados con el sueño [8]. En particular, se ha observado que la frecuencia de eventos CAP es significativamente superior en personas con limitación del flujo inspiratorio comparado con sujetos sanos [11]. De igual manera, incrementos en los ciclos CAP están vinculados con trastornos del sueño como la apnea del sueño, insomnio, movimientos periódicos de las piernas, síndrome de piernas inquietas, parasomnias como el trastorno de conducta del sueño REM y epilepsia frontal nocturna [8] [12]. El CAP también es útil para detectar anomalías espontáneas como el complejo K, asociado con condiciones como Alzheimer y epilepsia [13].

El CAP refleja de manera precisa la inestabilidad del sueño, no obstante, su análisis no ha sido completamente adoptado en la práctica clínica debido a diversas limitaciones. El actual método gold estándar para la evaluación del CAP es mediante la identificación visual de las fases del CAP por especialistas entrenados, lo cual es tedioso y consume mucho tiempo, y además está sujeto a errores humanos que pueden llevar a una categorización inexacta [12] [14]. Además, la sutileza y complejidad de las señales EEG hacen que sin las herramientas adecuadas, la interpretación no solo sea un desafío, sino también sea susceptible a imprecisiones significativas [15]. Ante estos retos, surge la necesidad de desarrollar métodos automáticos de análisis de EEG que sean eficientes y precisos. En años recientes, el desarrollo de algoritmos y métodos de análisis automático del CAP, al igual de marcadores basados en el CAP, han empezado a facilitar el uso más generalizado del CAP en el diagnóstico de patologías del sueño [5] [8].

II. ANTECEDENTES

Entre los diversos modelos automáticos desarrollados para la detección CAP en los últimos años, muchos de estos han utilizado técnicas de aprendizaje automático (machine learning; ML) y aprendizaje profundo (deep learning; DL) debido a la facilidad de implementación y menor margen de error. En el caso de ML, la selección y extracción de características representan los mayores desafíos, ya que requieren datos preprocesados de alto nivel. En contraste, DL integra la extracción de características dentro de las capas neuronales, lo que disminuye la necesidad de preprocesamiento de datos. Aunque el rendimiento de clasificación de ambas técnicas es similar, los modelos basados en DL han reportado un rendimiento ligeramente superior. Los clasificadores de ML más utilizados son SVM y KNN, mientras que 1D-CNN es frecuente en DL [5].

En el estudio de Loh et al. [12], se propone un modelo de aprendizaje profundo basado en redes neuronales convolucionales de una dimensión (1D-CNN) para la detección del CAP y la clasificación de tres etapas del sueño (vigilia, REM y NREM). El modelo, desarrollado a partir de registros EEG estandarizados, alcanzó una exactitud de clasificación del 90.46% para las etapas del sueño y del 73.64% en un dataset equilibrado de CAP, con una sensibilidad del 92.06% en un dataset desequilibrado. Este estudio destaca la dificultad de profesionales expertos para discernir cambios sutiles en las señales EEG durante el sueño NREM.

En otro estudio realizado por Murarka et al. [16], se presenta un enfoque para la clasificación de fases del CAP en el sueño utilizando también una red neuronal convolucional unidimensional (1-D CNN), que se destaca por no requerir preprocesamiento y utilizar únicamente un solo canal de grabaciones de EEG. Aplicado a datasets balanceados de sujetos sanos y pacientes con distintos trastornos del sueño (narcolepsia, trastorno del comportamiento del sueño REM, movimientos periódicos de las piernas, epilepsia nocturna del lóbulo frontal e insomnio), el modelo alcanzó una exactitud máxima del 78.84% en sujetos sanos y entre el 70% y el 82.21% en pacientes con trastornos. Estos resultados indican que el modelo propuesto mejora la exactitud en comparación con métodos anteriores, además de reducir la complejidad computacional, ofreciendo una herramienta práctica y eficiente para la categorización automatizada de las fases CAP.

Por otro lado, Sharma et al. [17] se centraron en el uso en un banco de filtros wavelet biortogonales (BOWFB) para identificar las fases del CAP. El modelo de aprendizaje automático desarrollado utilizó varios algoritmos de ML supervisados y logró una exactitud media de clasificación del 74.40%, y una exactitud máxima del 87.83% con un dataset desequilibrado. El modelo fue validado con técnicas como validación cruzada y validación hold out.

Además, en otro estudio [18] presentaron un modelo denominado CAPSCNet, que es basa en una variante de CNN llamada red de dispersión wavelet (WSN), para detectar automáticamente las fases A del CAP en señales EEG. Las

WSNs son más sencillas y computacionalmente más eficientes que las redes neuronales convolucionales (CNN). En este estudio, la WSN empleada extrae automáticamente características de los datos de EEG, y luego estas características son introducidas en diferentes clasificadores de ML supervisados. Este modelo CAPSCNet alcanzó una exactitud de clasificación promedio del 83.4% con un clasificador de red neuronal tricapa en datos de sujetos sanos. Este estudio utilizó variantes de datos de siete cohortes de sueño CAP para probar el modelo, destacando su eficacia y velocidad computacional.

Asimismo, Kahana et al. [19] exploraron un algoritmo automático basado en DL que utiliza arquitectura de 2D-CNN para clasificar señales EEG según sus representaciones tiempo-frecuencia. Este estudio emplea representaciones basadas en Wigner, las cuales superan a la transformada de Fourier de tiempo corto comúnmente utilizada para la clasificación del CAP. El algoritmo, que también incorpora técnicas de aumento de datos para preservar la estructura tiempo-frecuencia, logró una exactitud del 77.5% en un dataset de testeo equilibrado y del 81.8% en uno desequilibrado, lo cual muestra su potencial para mejorar procedimientos de identificación del CAP.

III. MATERIALES Y MÉTODOS

A. Participantes y Datasets

Los datos empleados en este proyecto se obtuvieron de la CAP Sleep Database, una base de datos de acceso público que contiene 108 grabaciones polisomnográficas [20]. Estas grabaciones incluyen diversas señales, como EEG (3 canales), EOG (2 canales), EMG mentoniana y tibial, señales de respiración (flujo aéreo, esfuerzo abdominal y torácico y SaO₂) y EKG. Cada grabación, con una duración de un poco más de 8 horas, cuenta con anotaciones de referencia de las fases del sueño y del CAP.

Respecto a los sujetos de estudio, la base de datos registra 16 individuos sanos, sin trastornos neurológicos y libres de medicamentos que afecten al sistema nervioso central. Además, se cuenta con 92 individuos diagnosticados con alguna patología del sueño, distribuidos de la siguiente manera: 2 sujetos con bruxismo, 9 con insomnio, 5 con narcolepsia, 40 con epilepsia nocturna del lóbulo frontal, 10 con movimientos periódicos de las piernas, 22 con trastorno del comportamiento REM y 4 con trastornos respiratorios del sueño. Los datos se adquirieron durante la noche, con una duración aproximada de 9 a 10 horas.

B. Preprocesamiento de datos

Los datos balanceados y preprocesados de CAP Sleep Database fueron obtenidos mediante la extracción de segmentos de tiempo de la misma forma en la que fueron extraídos para la creación de una red 1D-CNN de clasificación [16]. Se utilizaron las señales EEG que presentaban una frecuencia de muestreo (f_s) de 512 Hz y se utilizó el canal F4-C4. Estos datos fueron posteriormente divididos en periodos de 2 segundos (T). Únicamente se seleccionaron los datos de sueño correspondientes a las fases A y B del CAP. Para cada señal

se utilizaron 1024 muestras ($n = 1024$). La relación entre los parámetros de adquisición de la señal se muestra en (1):

$$T = \frac{n}{f_s} = 2 \text{ s} \quad (1)$$

Los data obtenida incluye 9306 señales de 6 pacientes sanos balanceada equitativamente, para obtener el mismo número de señales con fases A y B. Para el experimento, también se seleccionaron pacientes con distintas patologías. La distribución de las señales balanceadas para cada patología incluye:

- 6 Pacientes con insomnio, generando un total de 9960 señales.
- 5 Pacientes con narcolepsia, generando un total de 9558 señales.
- 40 Paciente con Epilepsia nocturna del lóbulo frontal (NFLE), generando un total de 73263 señales.
- 8 Pacientes con Trastorno de movimientos periódicos de las extremidades (PLM) generando un total de 17934
- 22 Pacientes con trastorno de conducta del sueño REM (RBD) generando un total de 44100 señales.

Asimismo, para la clasificación de patologías se balanceó las muestras de tres patologías específicas: bruxismo (BRU), trastorno de movimientos periódicos de las extremidades (PLM) y respiración alterada del sueño (SDB). La principal diferencia es que en este caso se utilizó una ventana de 30 segundos como entrada. Se aplicó un submuestreo aleatorio para obtener un número equilibrado de 780 muestras para cada una de estas tres patologías. Luego, se codificaron las etiquetas y se aplicó una codificación. Esto constituye la data combinada.

C. Clasificador de fases y de patologías del sueño

Para este estudio se desarrollaron dos clasificadores: uno para fases A y B, y otro para patologías del sueño. Para el clasificador de fases A y B, se utilizó un conjunto de datos balanceado de pacientes con diversas patologías del sueño (insomnio, narcolepsia, NFLE, PLM y RBD) de manera separada.

Por otro lado, el clasificador de patologías del sueño se entrenó utilizando la data combinada de las tres patologías mencionadas anteriormente: BRU, PLM y SDB.

1) *1-D CNN*: En el modelo se emplea una red neuronal convolucional unidimensional (1-D CNN) para procesar los datos. Las CNN generan nuevos atributos con mayor información a partir de una capa previa de convolución. Posteriormente, se reduce la dimensionalidad mediante una capa de Max Pooling. Además, cada una de estas capas presenta una función de activación. Finalmente, la salida de estas capas se conecta a una capa densamente conectada que prepara la salida final.

Se utilizó una CNN 1-D para ambas arquitecturas: el clasificador de fases y el clasificador de patologías. En ambos clasificadores se utilizó la función de activación ReLU en cada capa, con excepción de la última. Para la última capa, se usó una función sigmoide en el clasificador de fases y una función softmax en el clasificador de patologías.

Tabla I
ARQUITECTURA DETALLADA DEL CLASIFICADOR DE FASES

| Capa (tipo) | Forma de salida | Parámetros entrenables |
|---------------|------------------|------------------------|
| Conv 1D | (None, 1022, 64) | 128 |
| Conv 1D | (None, 1020, 8) | 776 |
| MaxPooling 1D | (None, 63, 8) | 0 |
| Conv 1D | (None, 61, 8) | 200 |
| MaxPooling 1D | (None, 15, 8) | 0 |
| Dropout (0.5) | (None, 15, 8) | 0 |
| GRU | (None, 8) | 432 |
| Dropout (0.5) | (None, 8) | 0 |
| Dense | (None, 16) | 144 |
| Dense | (None, 8) | 136 |
| Dense | (None, 2) | 18 |

2) *LSTM*: El LSTM (Long Short-Term Memory) es un tipo de red neuronal recurrente comúnmente utilizado en datos secuenciales o análisis de series temporales. Estas redes están basadas en celdas de memoria diseñadas para almacenar información durante largos períodos de tiempo y también para retener información a corto plazo.

La LSTM consiste en tres compuertas o gates: la compuerta de entrada (input gate), la compuerta de olvido (forget gate) y la compuerta de salida (output gate). Estas compuertas deciden el flujo de información basándose en el dato de entrada actual, los estados internos previos (memoria a largo plazo y a corto plazo). La compuerta de olvido principalmente determina cuánta información previa se conservará para las siguientes iteraciones.

Las entradas de las compuertas se determinan principalmente mediante sus funciones de activación, comúnmente funciones sigmoide y tangente hiperbólica para asegurar valores dentro del rango [0,1] y [-1,1] respectivamente. Las ecuaciones actualizadas se presentan a continuación (2).

$$\begin{aligned}
 h(t) &= g_o(t) \cdot f_h(s(t)) \cdot s(t-1) \\
 s(t) &= g_f(t) \cdot s(t-1) + g_i(t) \cdot f_s(w_h(t-1)) + u_X(t) + b \\
 g_i(t) &= \sigma(w_i h(t-1) + u_i X(t) + b_i) \\
 g_f(t) &= \sigma(w_f h(t-1) + u_f X(t) + b_f) \\
 g_o(t) &= \sigma(w_o h(t-1) + u_o X(t) + b_o)
 \end{aligned} \quad (2)$$

Donde h representa la salida en el tiempo t , s es el estado interno, g_o , g_f , g_i y g_o son las funciones de las compuertas, f_h y f_s son funciones de activación para los estados, w y u son pesos ajustables de la matriz, y b son los sesgos. Es importante destacar que los valores de los pesos no varían para permitir la entrada de secuencias largas.

Se utilizó una LSTM para el clasificador de patologías del sueño, mientras que se usó una variante de esta misma arquitectura llamada Gated Recurrent Unit (GRU) para el clasificador de fases. Ambas arquitecturas se detallan en la Tabla I y Tabla II, respectivamente.

Tabla II
ARQUITECTURA DETALLADA DEL CLASIFICADOR DE ENFERMEDADES

| Capa (tipo) | Forma de salida | Parámetros entrenables |
|---------------|-----------------|------------------------|
| Reshape | (None, 30, 512) | 0 |
| LSTM | (None, 256) | 787456 |
| Dense | (None, 32) | 8224 |
| Dropout (0.2) | (None, 32) | 0 |
| Dense | (None, 3) | 99 |




Figura 1. Función de pérdida y exactitud del clasificador de fases A y B para el caso saludable.

El optimizador seleccionado fue Adam, con una función de pérdida de entropía cruzada y exactitud como la métrica principal en ambos clasificadores. El clasificador de fases se entrenó durante 1000 épocas y el clasificador de patologías durante 30 épocas.

IV. RESULTADOS

Los principales resultados obtenidos de la arquitectura LSTM-CNN para la predicción de fases A y B fueron los presentados en las Figuras 1, 2, 3 y 4, donde se presentan las gráficas de pérdida y exactitud del conjunto de entrenamiento y validación para 1000 épocas. Se intentó corregir el overfitting utilizando regularización L1 y L2, sin embargo esto no mejoró los resultados. La matriz de confusión del testeo de estos casos se muestra en las Figuras 5, 6, 7 y 8, donde las etiquetas 1 y 0 corresponden a las fases A y B, respectivamente.

Con respecto a la clasificación de enfermedades, se obtuvieron los resultados presentados en la Figura 9 para 30 épocas. En este caso se presentó overfitting durante el




Figura 2. Función de pérdida y exactitud del clasificador de fases A y B para insomnio.




Figura 3. Función de pérdida y exactitud del clasificador de fases A y B para narcolepsia.




Figura 4. Función de pérdida y exactitud del clasificador de fases A y B para PLM.




Figura 5. Matriz de confusión del clasificador de fases A y B para el caso saludable.




Figura 6. Matriz de confusión del clasificador de fases A y B para insomnio.




Figura 7. Matriz de confusión del clasificador de fases A y B para narcolepsia.




Figura 8. Matriz de confusión del clasificador de fases A y B para PLM.

entrenamiento; sin embargo, para el conjunto de validación y testeo se obtuvieron valores de exactitud de 76.00% y 76.36%, respectivamente. De la misma forma que la clasificación anterior, se elaboró una matriz de confusión que se presenta en la Figura 10.

V. DISCUSIÓN

Estudios previos como Loh et al. [12] y Murarka et al. [16] emplearon 1D-CNN para la clasificación de las fases A y B, con el primero limitado a participantes sanos y el segundo incluyendo a participantes con diversos trastornos. El estudio de Sharma et al. [17] clasificó las fases CAP solo para pacientes sanos, a partir de una técnica de extracción de características basadas en wavelet antes del uso de clasificadores ensemble, lo cual sugiere un aumento en la complejidad computacional. Por otro lado, Kahana et al. [19] emplea representaciones tiempo-frecuencia de las fases CAP y también limita su análisis a señales de pacientes sanos.

En el presente estudio, se ha realizado una clasificación de las fases CAP de sujetos sanos y con trastornos de sueño, empleando un modelo de 1D-CNN, que al igual que en [16], no requiere etapa alguna de pre o post procesamiento. La comparación de pacientes con trastornos de sueño de este estudio y el de Murarka et al. [16] se muestra en la Tabla III. Para la narcolepsia, el modelo de Murarka et al. [16] mostró una exactitud, precisión, sensibilidad y especificidad del 82.21%, 82.09%, 82.60% y 82.34%, respectivamente. En contraste, nuestro modelo mejoró significativamente todos estos parámetros, alcanzando una exactitud de 86.98%, precisión

de 87.66%, sensibilidad de 85.71% y especificidad de 88.21%. En el caso de PLM, mientras que el estudio previo reportó una exactitud de 78.72%, nuestro modelo obtuvo una exactitud menor de 75.83%. Sin embargo, se consiguió mejoras en la precisión y la especificidad, alcanzando un 87.83% y 91.78% respectivamente, aunque con una disminución en la sensibilidad a 59.76%. Para los pacientes con insomnio, el estudio anterior reportó una exactitud de 70.88%. Nuestro modelo mostró una mejora a 76.71% en exactitud. Además, se registraron mejoras en la precisión y la sensibilidad, que se elevaron a 83.43% y 68.07% respectivamente, mientras que la especificidad mostró una leve disminución a 85.79%. Los resultados indican mejoras significativas en la mayoría de los parámetros de rendimiento, especialmente en los casos de narcolepsia e insomnio, resaltando la efectividad de nuestro modelo de clasificación de fases CAP desarrollado.

Tabla III
COMPARACIÓN DE RESULTADOS DE CLASIFICACIÓN CAP EN SUJETOS CON TRASTORNOS DE SUEÑO USANDO DATASETS BALANCEADOS.

| Tipo de enfermedad | Estudio | Parámetros de rendimiento (%) | | | |
|--------------------|---------------------|-------------------------------|--------------|--------------|---------------|
| | | Exactitud | Precisión | Sensibilidad | Especificidad |
| Narcolepsia | Murarka et al. [16] | 82.21 | 82.09 | 82.60 | 82.34 |
| | Este trabajo | 86.98 | 87.66 | 85.71 | 88.21 |
| PLM | Murarka et al. [16] | 78.72 | 83.98 | 71.64 | 85.99 |
| | Este trabajo | 75.83 | 87.83 | 59.76 | 91.78 |
| Insomnio | Murarka et al. [16] | 70.88 | 81.82 | 56.52 | 86.41 |
| | Este trabajo | 76.71 | 83.43 | 68.07 | 85.79 |

En la Tabla IV se observa los resultados de diversos estudios de detección de CAP que usan solo datasets de sujetos sanos, provenientes además de la CAP Sleep Database. El modelo 1D-CNN empleado en este estudio, presenta resultados destacables en comparación con estudios anteriores. En comparación con el modelo 1D-CNN de Murarka et al. [16], que alcanzó una exactitud del 78.84% y una especificidad del 84.26%, nuestro modelo mostró una ligera disminución en la exactitud a 78.46%, pero una mejora significativa en la especificidad, alcanzando el 88.00%. Aunque nuestra sensibilidad fue menor (68.89% frente a 73.44%), la precisión de nuestro modelo fue superior, registrando un 85.11% frente al 82.45% de ese estudio previo. En contraste con el modelo de Loh [12], que presentó una exactitud de 73.64% y una especificidad de 66.95%, nuestro estudio demostró mejoras significativas en ambos parámetros, con una superioridad notable en la especificidad. Esto refleja una mejora en la capacidad del presente modelo para identificar correctamente las fases B, lo que es crucial para evitar la clasificación errónea de fases A como B. Frente al método de representaciones Wigner [19] y el banco de filtros wavelet biortogonales [17], que mostraron una exactitud de 77.50% y 73.43% respectivamente, nuestro modelo demostró ser competitivo, manteniendo una precisión consistente y ofreciendo la mejor especificidad entre los métodos comparados. Por lo que el modelo clasificador de fases CAP no solo mantiene una alta precisión y especificidad, sino que




Figura 9. Función de pérdida y exactitud del modelo de clasificación de patologías del sueño.




Figura 10. Matriz de confusión de la clasificación de patologías del sueño.

también se destaca por su robustez en identificar correctamente las fases B, lo cual es importante para aplicaciones clínicas donde la identificación precisa de las fases de sueño es crítica.

Se ha desarrollado un modelo preliminar para la clasificación de patologías utilizando las ventanas de 30 segundos del canal F4-C4. Sin embargo, durante su evaluación se observaron discrepancias significativas entre las métricas de entrenamiento y validación. En la Figura 9, se puede apreciar un claro overfitting en la función de exactitud. A pesar de ello, la precisión alcanzada en la validación fue del 76 %, en comparación con un 99 % en el conjunto de entrenamiento. Respecto a la función de pérdida, se encontró también un overfitting, con una pérdida de 0.129 en entrenamiento y 1.016 en validación.

Además, la matriz de confusión (véase la Figura 10) mostró una alta capacidad para identificar la mayoría de las enfermedades en cada ventana. A pesar del overfitting, hay que destacar que se obtienen resultados consistentes en los conjuntos de validación y testeo, por lo que se puede

notar que el modelo tiene una capacidad de generalización adecuada para los datos presentados. Esto sugiere que, aunque el modelo pueda estar ajustándose excesivamente a los datos de entrenamiento, sigue siendo capaz de capturar patrones relevantes que se aplican bien a datos no vistos.

VI. LIMITACIONES DEL ESTUDIO

Las principales limitaciones del presente trabajo corresponden a la clasificación de patologías, ya que no se consideró el número total de patologías de la CAP Sleep Database. Futuros estudios se deben enfocar en abarcar una mayor cantidad de patologías mediante el uso de uno o más canales EEG.

Con respecto a la clasificación de fases, la limitante más destacada es que esta se realiza independientemente para cada patología. En consecuencia, para un funcionamiento óptimo se requiere saber tentativamente la patología de cada sujeto. Esto se puede lograr mediante el análisis por parte de un médico o, en todo caso, del resultado de la clasificación de patologías obtenido mediante un modelo de DL como el presentado en este estudio.

VII. CONCLUSIONES

En conclusión, respecto al clasificador de fases propuesto, este presenta mejores métricas en la mayoría de las patologías elegidas. Sin embargo, todavía no puede aplicarse a todas las patologías descritas en el CAP Sleep Database. Por lo tanto, es necesario realizar un análisis exploratorio previo para determinar si otras enfermedades, aparte de las descritas en el estudio, pueden ser probadas.

Para el caso del clasificador de patologías, se ha logrado clasificar 3 de las presentes en la base de datos mencionada. Aún existen limitaciones que deben ser estudiadas en estudios futuros.

REFERENCIAS

- [1] M. Tahmasian, F. Samea, H. Khazaie, M. Zarei, S. K. Masouleh, F. Hoffstaedter, J. Camilleri, P. Kochunov, B. T. Yeo, S. B. Eickhoff, and S. L. Valk, "The interrelation of sleep and mental and physical health is anchored in grey-matter neuroanatomy and under genetic control," *Communications Biology*, vol. 3, 2020.

Tabla IV
COMPARACIÓN DE RESULTADOS DE CLASIFICACIÓN CAP EN SUJETOS SANOS CON DATASETS BALANCEADOS.

| Método | N° de muestras utilizadas | Frec. de muestreo (Hz) | Parámetros de rendimiento (%) | | | |
|---|---------------------------|------------------------|-------------------------------|--------------|--------------|--------------|
| | | | Exact. | Prec. | Sens. | Espec. |
| Banco de filtros wavelet biortogonales (BOWFB) [17] | Fases A: 4653 | 512 | 73.43 | 67.38 | 76.59 | 70.95 |
| Representaciones Wigner [19] | Fases A: 3937 | 32 | 77.50 | 78.40 | 75.90 | 79.10 |
| 1D-CNN [12] | Fases A: 4653 | 512 | 73.64 | 70.96 | 80.29 | 66.95 |
| 1D-CNN [16] | Fases A: 4653 | 512 | 78.84 | 82.45 | 73.44 | 84.26 |
| 1D-CNN (trabajo actual) | Fases A: 4653 | 512 | 78.46 | 85.11 | 68.89 | 88.00 |

- [2] E. Tobaldini, G. Costantino, M. Solbiati, C. Cogliati, T. Kara, L. Nobili, and N. Montano, "Sleep, sleep deprivation, autonomic nervous system and cardiovascular diseases," *Neuroscience & Biobehavioral Reviews*, vol. 74, pp. 321–329, 2017, stress, Behavior and the Heart. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0149763416302184>
- [3] K. R. Sewell, K. I. Erickson, S. R. Rainey-Smith, J. J. Peiffer, H. R. Sohrabi, and B. M. Brown, "Relationships between physical activity, sleep and cognitive function: A narrative review," *Neuroscience & Biobehavioral Reviews*, vol. 130, pp. 369–378, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0149763421003857>
- [4] S. C. Liew and T. Aung, "Sleep deprivation and its association with diseases- a review," *Sleep Medicine*, vol. 77, pp. 192–204, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1389945720303701>
- [5] M. Sharma, H. Lodhi, R. Yadav, H. Elphick, and U. R. Acharya, "Computerized detection of cyclic alternating patterns of sleep: A new paradigm, future scope and challenges," *Computer Methods and Programs in Biomedicine*, vol. 235, p. 107471, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0169260723001372>
- [6] U. Seneviratne, M. Cook, and W. D'Souza, "Epileptiform k-complexes and sleep spindles: An underreported phenomenon in genetic generalized epilepsy," *Journal of Clinical Neurophysiology*, vol. 33, no. 2, 2016.
- [7] Y. Gu, J.-F. Gagnon, and M. Kaminska, "Sleep electroencephalography biomarkers of cognition in obstructive sleep apnea," *Journal of Sleep Research*, vol. 32, no. 5, p. e13831, 2023.
- [8] D. Gu, Y. Mi, and A. Lin, "Application of time-delay multiscale symbolic phase compensated transfer entropy in analyzing cyclic alternating pattern (cap) in sleep-related pathological data," *Communications in Nonlinear Science and Numerical Simulation*, vol. 99, p. 105835, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1007570421001477>
- [9] R. Ferri, R. Huber, D. Aricò, V. Drago, F. Rundo, M. F. Ghilardi, M. Massimini, and G. Tononi, "The slow-wave components of the cyclic alternating pattern (cap) have a role in sleep-related learning processes," *Neuroscience Letters*, vol. 432, no. 3, pp. 228–231, 2008. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0304394007012992>
- [10] L. Parrino, R. Ferri, O. Bruni, and M. G. Terzano, "Cyclic alternating pattern (cap): The marker of sleep instability," *Sleep Medicine Reviews*, vol. 16, no. 1, pp. 27–45, 2012.
- [11] A. Parekh, K. Kam, A. E. Mullins, B. Castillo, A. Berkaliyeva, M. Mazumdar, A. W. Varga, D. J. Eckert, D. M. Rapoport, and I. Ayappa, "Altered K-complex morphology during sustained inspiratory airflow limitation is associated with next-day lapses in vigilance in obstructive sleep apnea," *Sleep*, vol. 44, no. 7, p. zsab010, 01 2021.
- [12] H. W. Loh, C. P. Ooi, S. G. Dhok, M. Sharma, A. A. Bhurane, and U. R. Acharya, "Automated detection of cyclic alternating pattern and classification of sleep stages using deep neural network," *Applied Intelligence*, vol. 52, 2022.
- [13] M. H. Gandhi and P. D. Emmady, "Physiology, K Complex," in *StatPearls*. Treasure Island (FL): StatPearls Publishing, 2024. [Online]. Available: <http://www.ncbi.nlm.nih.gov/books/NBK557469/>
- [14] M. P. Tramonti Fantozzi, U. Faraguna, A. Ugon, G. Ciuti, and A. Pinna, "Automatic cyclic alternating pattern (cap) analysis: Local and multi-trace approaches," *Plos one*, vol. 16, no. 12, p. e0260984, 2021.
- [15] Z. Wan, R. Yang, M. Huang, N. Zeng, and X. Liu, "A review on transfer learning in eeg signal analysis," *Neurocomputing*, vol. 421, pp. 1–14, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231220314223>
- [16] S. Murarka, A. Wadichar, A. Bhurane, M. Sharma, and U. R. Acharya, "Automated classification of cyclic alternating pattern sleep phases in healthy and sleep-disordered subjects using convolutional neural network," *Computers in Biology and Medicine*, vol. 146, p. 105594, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482522003869>
- [17] M. Sharma, A. A. Bhurane, and U. R. Acharya, "An expert system for automated classification of phases in cyclic alternating patterns of sleep using optimal wavelet-based entropy features," *Expert Systems*, vol. 41, no. 5, p. e12939, 2024. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1111/exsy.12939>
- [18] M. Sharma, S. Verma, D. Anand, V. M. Gadre, and U. R. Acharya, "Capsnet: A novel scattering network for automated identification of phasic cyclic alternating patterns of human sleep using multivariate eeg signals," *Computers in Biology and Medicine*, vol. 164, p. 107259, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482523007242>
- [19] Y. Kahana, A. Aberdam, A. Amar, and I. Cohen, "Deep-learning-based classification of cyclic-alternating-pattern sleep phases," *Entropy*, vol. 25, no. 10, 2023. [Online]. Available: <https://www.mdpi.com/1099-4300/25/10/1395>
- [20] M. G. Terzano, L. Parrino, A. Sherieri, R. Chervin, S. Chokroverty, C. Guilleminault, M. Hirshkowitz, M. Mahowald, H. Moldofsky, A. Rosa, R. Thomas, and A. Walters, "Atlas, rules, and recording techniques for the scoring of cyclic alternating pattern (cap) in human sleep," *Sleep Medicine*, vol. 2, no. 6, pp. 537–553, 2001. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1389945701001496>