



UNIVERSIDAD PERUANA  
**CAYETANO HEREDIA**

# **Clasificadores Híbridos LSTM-1D CNN para la identificación de fases y patologías del patrón ciclico alternante del sueño (CAP)**

Grupo 3

Rodolfo Huacasi

Leonardo Sandoval

Daniel Zavaleta

---

Junio 2024

Reconocimiento de patrones

# Problemática

## De forma tradicional:


Evaluación de CAP (indicador de la estabilidad del sueño vinculado a múltiples trastornos)



Requiere un análisis visual detallado y laborioso por parte de especialistas entrenados



- Susceptible a errores humanos
- Proceso extenso y costoso en términos de tiempo y recursos



Restringe su aplicabilidad en diagnósticos rápidos y accesibles



## Entonces:

Detección deficiente e imprecisa de patologías del sueño debido a las limitaciones en los métodos actuales de análisis de los patrones de sueño, específicamente del Patrón Alternante Cíclico (CAP)


## Solución:



Desarrollar: 1) un modelo de aprendizaje automático que permita la clasificación de fases del CAP, 2) un modelo que permita la clasificación de patologías del sueño, haciendo uso de la CAP Sleep Database.

# Clasificador de fases A y B

## Metodología: Preprocesamiento de los datos

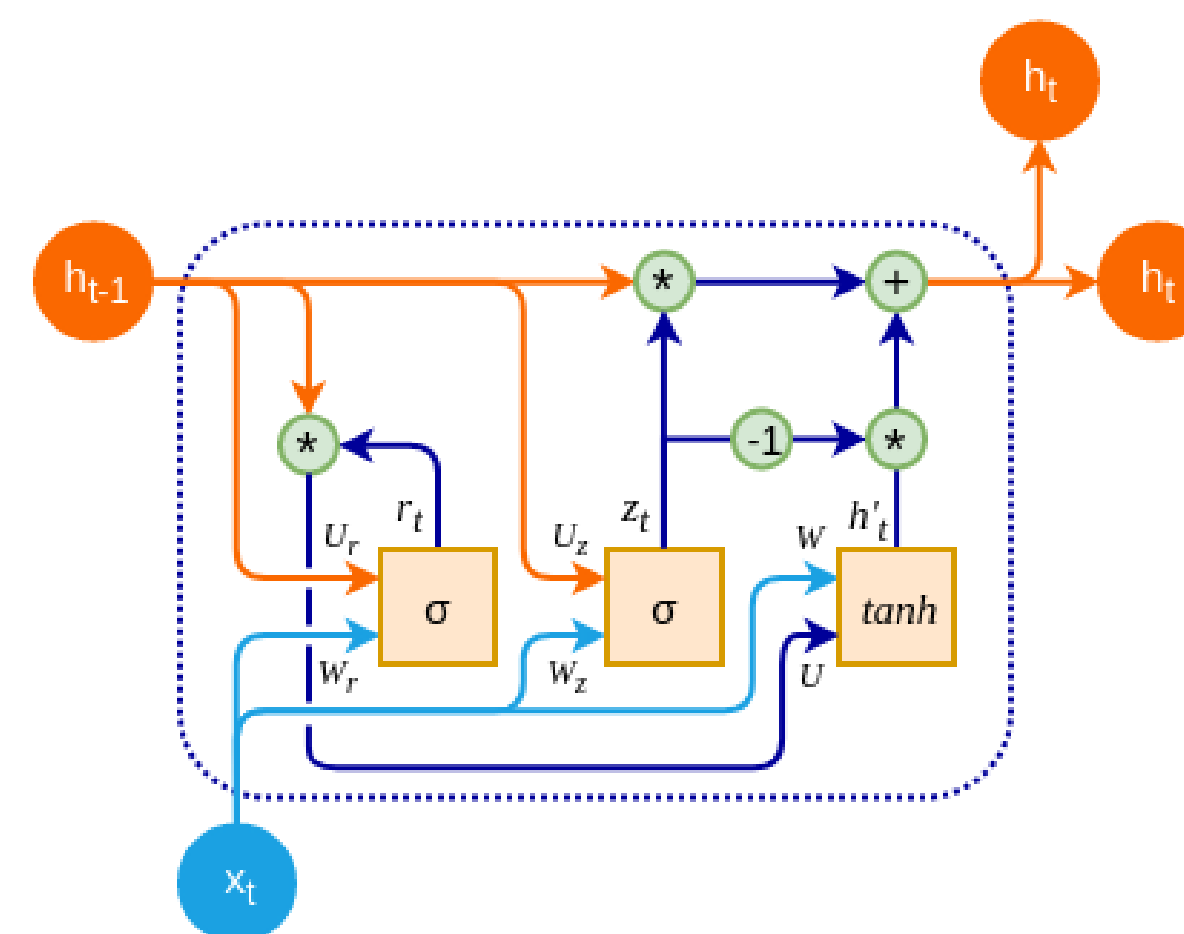


- 6 Pacientes con insomnio, generando un total de 9960 señales.
- 5 Pacientes con narcolepsia, generando un total de 9558 señales.
- 40 Paciente con Epilepsia nocturna del lóbulo frontal (NFLE), generando un total de 73263 señales.
- 8 Pacientes con Trastorno de movimientos periódicos de las extremidades (PLM) generando un total de 17934
- 22 Pacientes con trastorno de conducta del sueño REM (RBD) generando un total de 44100 señales.

# Clasificador de fases A y B

## Metodología: Desarrollo del modelo

| Capa (tipo)   | Forma de salida  | Parámetros entrenables |
|---------------|------------------|------------------------|
| Conv 1D       | (None, 1022, 64) | 128                    |
| Conv 1D       | (None, 1020, 8)  | 776                    |
| MaxPooling 1D | (None, 63, 8)    | 0                      |
| Conv 1D       | (None, 61, 8)    | 200                    |
| MaxPooling 1D | (None, 15, 8)    | 0                      |
| Dropout (0.5) | (None, 15, 8)    | 0                      |
| GRU           | (None, 8)        | 432                    |
| Dropout (0.5) | (None, 8)        | 0                      |
| Dense         | (None, 16)       | 144                    |
| Dense         | (None, 8)        | 136                    |
| Dense         | (None, 2)        | 18                     |



[1] A. Nama, "Understanding Gated Recurrent Unit (GRU) in Deep Learning," Medium, Jan. 8, 2020. [Online]. Available: <https://medium.com/@anishnama20/understanding-gated-recurrent-unit-gru-in-deep-learning-2e54923f3e2>. [Accessed: Jun. 26, 2024].

# Resultados

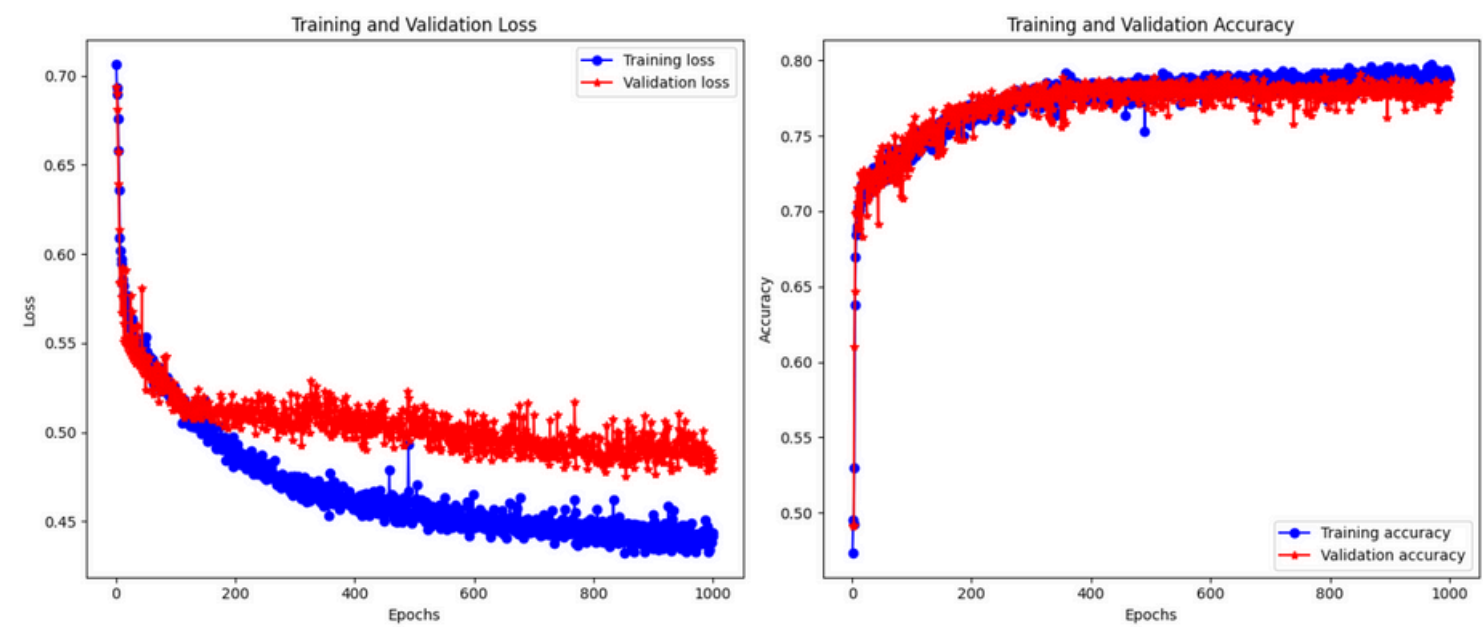


Figura 1. Función de pérdida y exactitud del clasificador de fases A y B para el caso saludable.

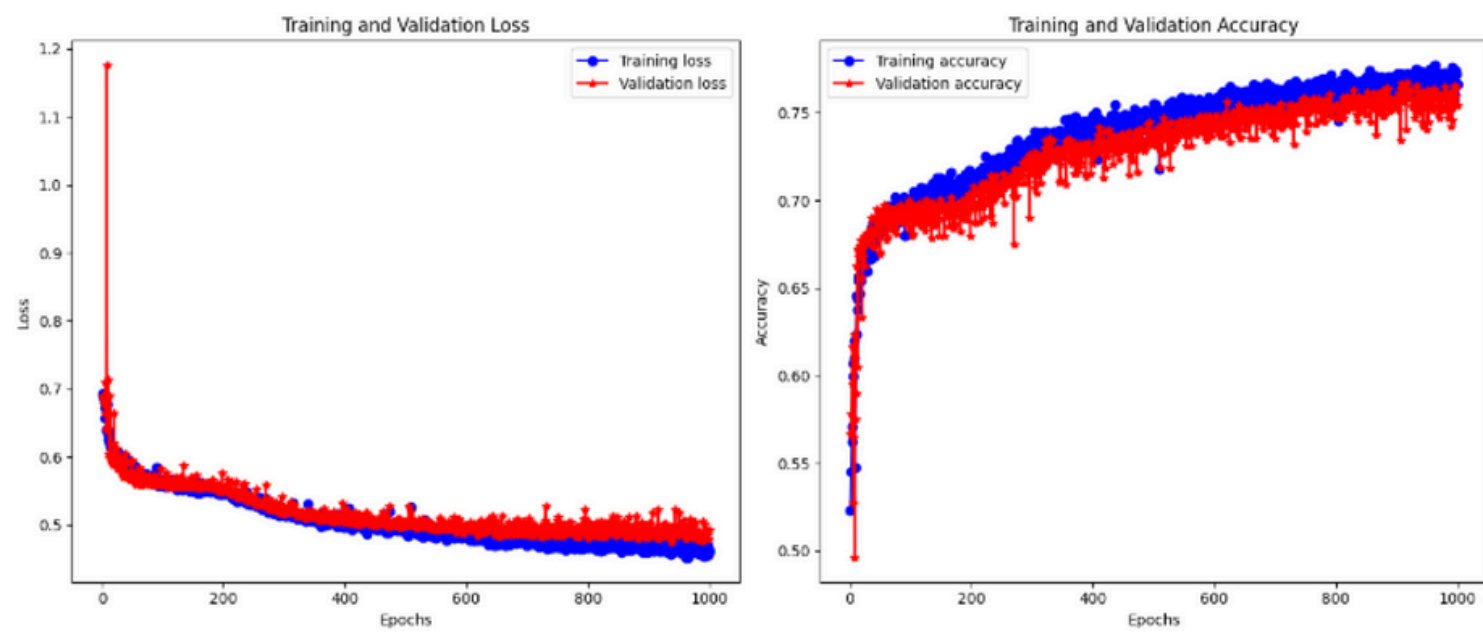


Figura 2. Función de pérdida y exactitud del clasificador de fases A y B para insomnio.




Figura 5. Matriz de confusión del clasificador de fases A y B para el caso saludable.




Figura 6. Matriz de confusión del clasificador de fases A y B para insomnio.



# Resultados




Figura 3. Función de pérdida y exactitud del clasificador de fases A y B para narcolepsia.

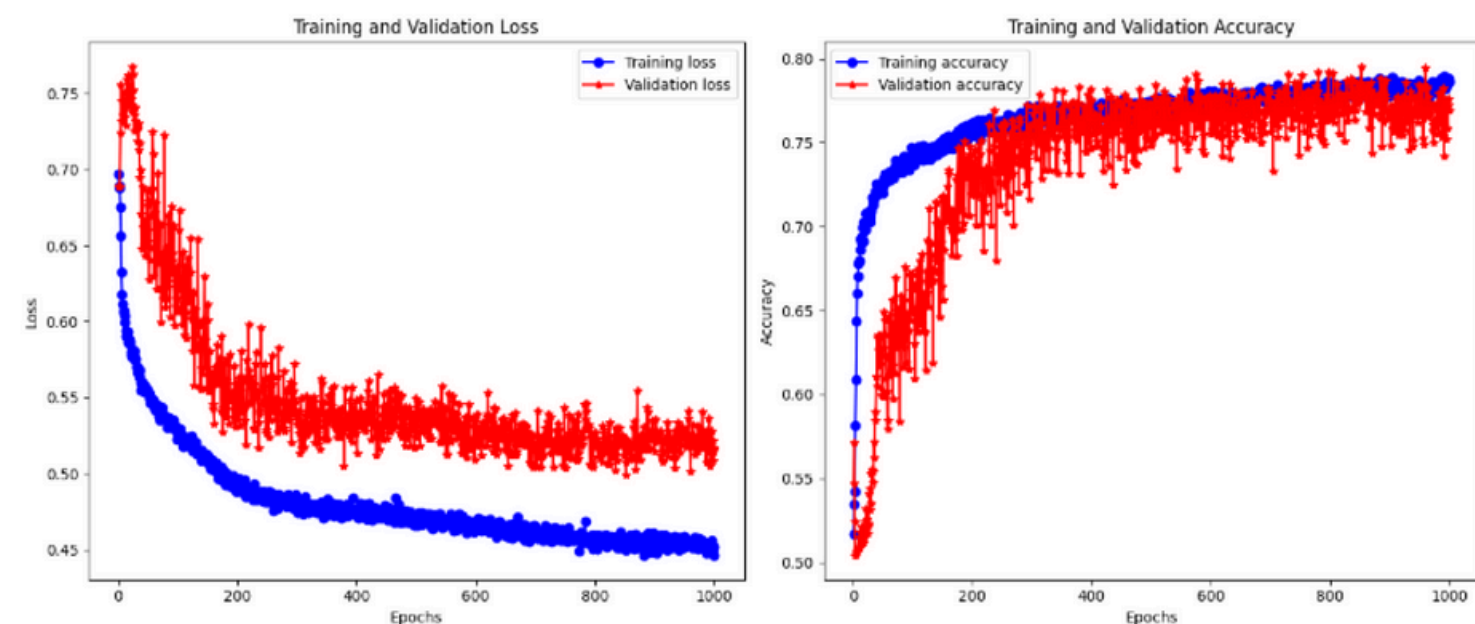


Figura 4. Función de pérdida y exactitud del clasificador de fases A y B para PLM.




Figura 7. Matriz de confusión del clasificador de fases A y B para narcolepsia.


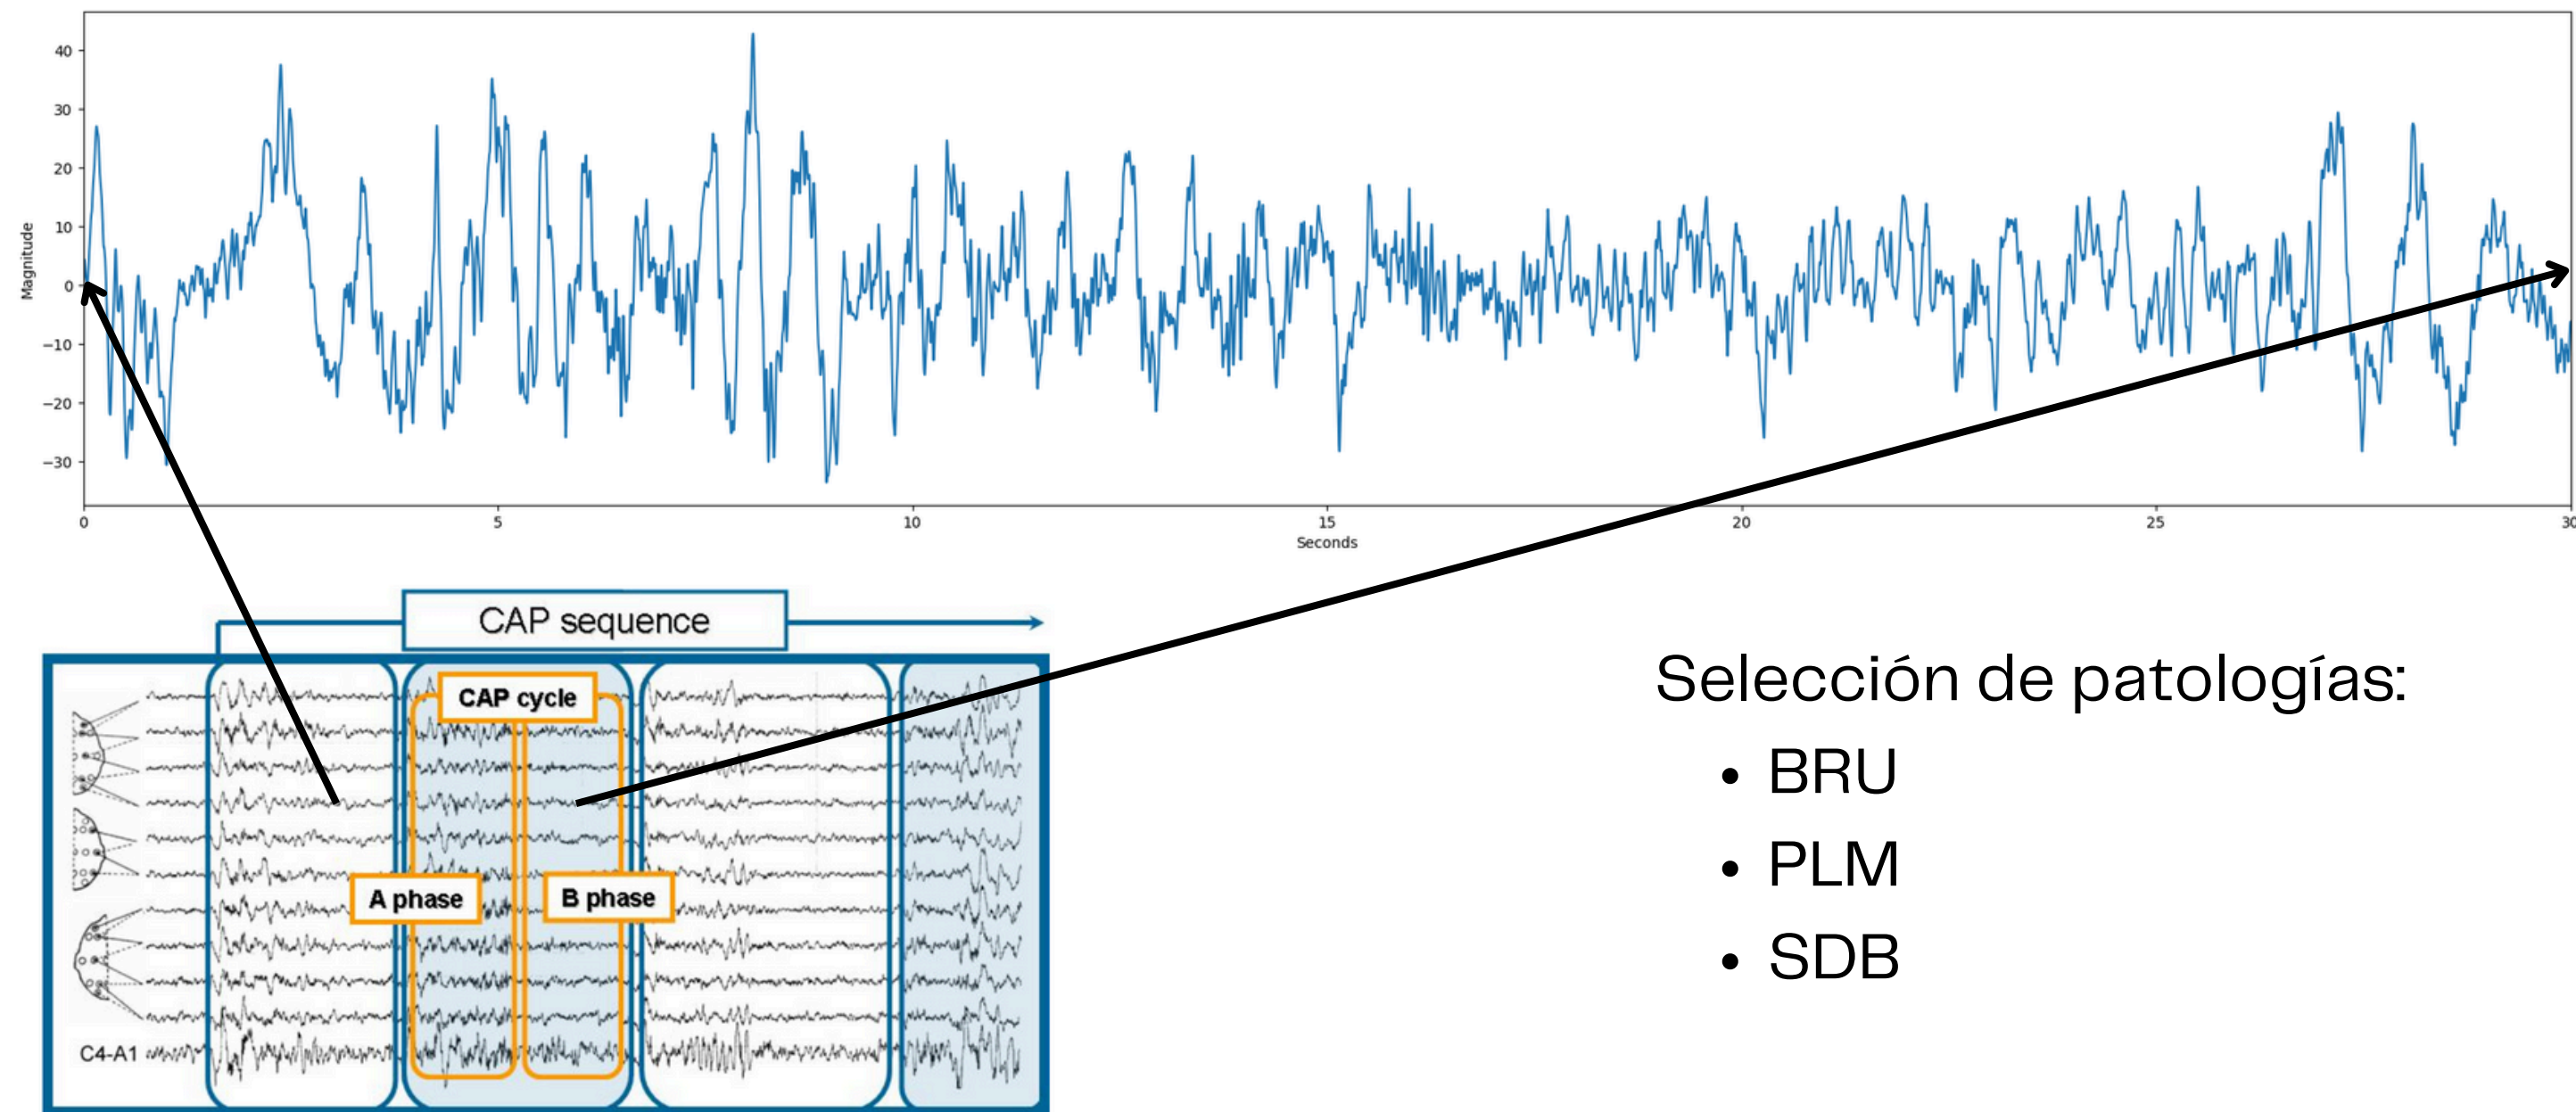


Figura 8. Matriz de confusión del clasificador de fases A y B para PLM.

# Clasificador de patologías

## Metodología: Preprocesamiento de los datos



Selección de patologías:

- BRU
- PLM
- SDB

# Clasificador de patologías

## Metodología: Desarrollo del modelo




| Capa (tipo)   | Forma de salida | Parámetros entrenables |
|---------------|-----------------|------------------------|
| Reshape       | (None, 30, 512) | 0                      |
| LSTM          | (None, 256)     | 787456                 |
| Dense         | (None, 32)      | 8224                   |
| Dropout (0.2) | (None, 32)      | 0                      |
| Dense         | (None, 3)       | 99                     |

[1] S. Gokulan, S. Narmadha, M. Pavithra, R. Rajmohan and T. Ananthkumar, "Determination of Various Deep Learning Parameter for Sleep Disorder," 2020 International Conference on System, Computation, Automation and Networking (ICSCAN), Pondicherry, India, 2020, pp. 1-6, doi: 10.1109/ICSCAN49426.2020.9262331.



# Clasificador de patologías

## Resultados



Validation Accuracy: 76.00%  
Test Accuracy : 75.43%

# Discusión

Tabla III

COMPARACIÓN DE RESULTADOS DE CLASIFICACIÓN CAP EN SUJETOS CON TRASTORNOS DE SUEÑO USANDO DATASETS BALANCEADOS.

| Tipo de enfermedad | Estudio             | Parámetros de rendimiento (%) |              |              |               |
|--------------------|---------------------|-------------------------------|--------------|--------------|---------------|
|                    |                     | Exactitud                     | Precisión    | Sensibilidad | Especificidad |
| Narcolepsia        | Murarka et al. [16] | 82.21                         | 82.09        | 82.60        | 82.34         |
|                    | Este trabajo        | <b>86.98</b>                  | <b>87.66</b> | <b>85.71</b> | <b>88.21</b>  |
| PLM                | Murarka et al. [16] | 78.72                         | 83.98        | 71.64        | 85.99         |
|                    | Este trabajo        | 75.83                         | <b>87.83</b> | 59.76        | <b>91.78</b>  |
| Insomnio           | Murarka et al. [16] | 70.88                         | 81.82        | 56.52        | 86.41         |
|                    | Este trabajo        | <b>76.71</b>                  | <b>83.43</b> | <b>68.07</b> | 85.79         |

# Discusión

Tabla IV

COMPARACIÓN DE RESULTADOS DE CLASIFICACIÓN CAP EN SUJETOS SANOS CON DATASETS BALANCEADOS.

| Método  | N° de muestras utilizadas | Frec. de muestreo (Hz) | Parámetros de rendimiento (%) |              |              |              |
|---|---------------------------|------------------------|-------------------------------|--------------|--------------|--------------|
|   |                           |                        | Exact.                        | Prec.        | Sens.        | Espec.       |
| Banco de filtros wavelet biortogonales (BOWFB) [17] | Fases A:<br>4653          | 512                    | 73.43                         | 67.38        | 76.59        | 70.95        |
| Representaciones Wigner [19]                        | Fases A:<br>3937          | 32                     | 77.50                         | 78.40        | 75.90        | 79.10        |
| 1D-CNN [12]   | Fases A:<br>4653          | 512                    | 73.64                         | 70.96        | 80.29        | 66.95        |
| 1D-CNN [16]   | Fases A:<br>4653          | 512                    | 78.84                         | 82.45        | 73.44        | 84.26        |
| <b>1D-CNN (trabajo actual)</b>                      | <b>Fases A:<br/>4653</b>  | <b>512</b>             | <b>78.46</b>                  | <b>85.11</b> | <b>68.89</b> | <b>88.00</b> |


# Limitaciones

## Clasificación de patologías:

- No se consideró el número total de patologías de la CAP Sleep Database.
- Futuros estudios enfocarse en abarcar mayor cantidad de patologías mediante el uso de uno o más canales EEG.

## Clasificación de fases CAP:

- Tampoco se considera todas las patologías de la base de datos, solo 3 trastornos y sujetos sanos.
- Estudio realizado con dataset balanceados de cantidad de fases A y B.





# Conclusiones

- El clasificador de fases CAP del presente estudio cuenta con mejores métricas en la mayoría de las patologías elegidas (narcolepsia, PLM, insomnio) que la literatura actual.
- El clasificador de fases CAP empleado en pacientes sanos cuenta con métricas similares o ligeramente mejores a la literatura actual.
- A futuro, realizar un análisis exploratorio para determinar si otras enfermedades pueden ser probadas en el clasificador de fases CAP.
- El clasificador de trastornos del sueño desarrollado logró clasificar 3 trastornos (bruxismo, PLM, SDB) del CAP Sleep Database con una exactitud mayor al 75%.

**¡Muchas  
gracias!**

